

APRENDIZAJE AUTOMÁTICO II

Anibal Sosa, PhD

Machine Learning



what society thinks I do




what my friends think I do



what my parents think I do

$$\begin{aligned}
 L_T &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i y_i (x_i \cdot w + b) + \sum_{i=1}^n \alpha_i \\
 \alpha_i &\geq 0, \forall i \\
 w &= \sum_{i=1}^n \alpha_i x_i, \sum_{i=1}^n \alpha_i y_i = 0 \\
 \nabla \hat{y}(\theta_t) &= \frac{1}{n} \sum_{i=1}^n \nabla \ell(x_i, y_i; \theta_t) + \nabla r(\theta_t) \\
 \theta_{t+1} &= \theta_t - \eta_t \nabla \ell(x_{t+1}, y_{t+1}; \theta_t) - \eta_t \cdot \nabla r(\theta_t) \\
 \mathbb{E}_{(x,y)} [\ell(x,y; \theta_t)] &= \frac{1}{n} \sum_{i=1}^n \ell(x_i, y_i; \theta_t)
 \end{aligned}$$

what other programmers think I do



what I think I do

```
>>> from scipy import svm
```

what I really do



ANIBAL SOSA

Formación

- Matemático de la Universidad del Valle, 2000
- Maestría en Ciencias Matemáticas, Universidad del Valle, 2004
- Maestría en Ciencias Computacionales, Universidad de Texas El Paso, USA, 2011
- Doctorado en Ciencias Computacionales, Universidad de Texas El Paso, USA, 2012

Experiencia académica

- Posdoctorado Cyber-ShARE Center of Excellence, Universidad Texas El Paso, USA, 2013
- Desde agosto 2004, profesor tiempo completo ICESI
- Ex-Becario Fulbright como profesor visitante en el Oak Ridge National Laboratory, Tennessee, USA, 2019



DESCRIPCIÓN

En este curso se introducen los conceptos básicos de la analítica de datos, presentando las características de los modelos de **aprendizaje automático** (***machine learning***), desde un enfoque teórico (introductorio) y práctico, distinguiendo entre los **modelos supervisados** (permitiendo la predicción) y **no supervisados** (encontrando patrones estructurales en los datos), y estudiando las **métricas de calidad** de los mismos y los **protocolos de evaluación** que permiten valorarlos y compararlos.



DESCRIPCIÓN

Aprendizaje Supervisado

- Modelos
 - Árboles de decision - ensambles.
 - SVM
- Bogota timeProtocolos de evaluación
 - Holdout
 - Validación cruzada (Cross Validation – CV)
- Sobreaprendizaje

Aprendizaje No Supervisado

- Modelos de clustering
 - K-Means
 - Jerárquico
 - DBScan (opcional)
- Análisis de Componentes Principales (PCA)




OBJETIVOS DE APRENDIZAJE

- RA1. Reconocer y resolver problemas de clasificación, regresión,
- RA3. Implementar algoritmos en Python para el entrenamiento y la evaluación de modelos de analítica, utilizando las métricas pertinentes al tipo de problema que solucionan
 - Aplicar modelos de K-NN y de regresión logística a conjuntos de datos, para responder a preguntas de negocio involucrando modelos de aprendizaje supervisado.
 - Comparar modelos de aprendizaje supervisado con respecto a métricas de ajuste, utilizando diferentes protocolos de evaluación






**Aprendizaje
automático**



Clasificación




**Métricas de
Evaluación de la
clasificación**




KNN




**Métricas de
Evaluación de la
regresión**



**Aprendizaje
no supervisado**



**Aprendizaje
supervisado**



Regresión



DATOS:
Materia prima

Posgrados

PREGUNTA:

¿Por qué?
¿Cómo?
¿Cuáles?
¿Cuándo?

ANALISIS EXPLORATORIO:
Limpieza de datos
Preparación / transformación
Escogencia de variables

MODELO:
Implementación del
modelo de analítica

EVALUACION:
Calidad del modelo
Ajuste del modelo

DESPLIEGUE:
Resultados
Conocimiento
Estrategia






Gartner[®] 10s

Hype Cycle

Tecnologías emergentes






Gartner[®] los Hype Cycle Tecnologías emergentes

**Big data y analítica
ya no se consideran
tecnologías emergentes!**



Hype Cycle for artificial Intelligence



Plateau will be reached:

○ less than 2 years

● 2 to 5 years

● 5 to 10 years

▲ more than 10 years

⊗ obsolete before plateau

As of July 2023

APRENDIZAJE AUTOMÁTICO (APRENDIZAJE DE MAQUINA VS APRENDIZAJE ESTADISTICO)

- El aprendizaje de máquina tiene que ver más con los resultados. En este sentido su valor será caracterizado únicamente por su rendimiento.
- En el aprendizaje estadístico se trata más de encontrar relaciones entre variables y la importancia de esas relaciones, al tiempo que se puede buscar una predicción.






Universidad
Icesi

MACHINE LEARNING

Posgrados





Universidad
Icesi

MACHINE LEARNING

Posgrados



Kasparov vencido por Deep Blue



Watson gana Jeopardy



The AI Forecaster: Machine Learning Takes on Weather Prediction



Improved weather forecasts from 2 weeks to 2 months could improve disaster preparedness for storms like Hurricane Irma, shown here battering Saint Martin in the Caribbean. A new machine learning weather prediction system shows promise on this subseasonal time frame. Credit: Netherlands Ministry of Defence, CC BY SA 4.0



QuantumBlack
AI by McKinsey

The state of AI in 2023: Generative AI's breakout year


August 1, 2023 | Survey



"Less than a year after many of these tools debuted, one-third of our survey respondents say their organizations are using gen AI regularly in at least one business function"


■ Definición:

El aprendizaje automático es la ciencia que permite a los computadores aprender, sin ser explícitamente programados¹




1. Andrew Ng, Stanford University, 2014

Modelo tradicional



Ciencia de datos



¿Cómo le puedo enseñar a un niño que es una pelota?

Set de entrenamiento



¿Qué patrones distinguen las pelotas de los demás juguetes?

¿Es esta una pelota?





Universidad
icesi

APRENDIZAJE NO SUPERVISADO

Posgrados

Organiza tus juguetes



¿Qué estructura hay en los datos?



Aprendizaje supervisado

- Aprender a partir de un “experto”
- Datos de entrenamiento **etiquetados** con una clase o valor:

$(\underline{x_1, x_2, \dots, x_n}, y)$

Predictores, variables de entrada
(independientes)

← Respuesta, variable de salida
(dependiente)

- **Meta:** predecir una clase o valor

Aprendizaje no supervisado

- Sin conocimiento de una clase o valor objetivo


- Los datos **no** están **etiquetados**

$(x_1, x_2, \dots, x_n)$

- **Meta:** descubrir patrones, estructura, factores no observados o una representación mas simple



Presupuestos de Publicidad



Aprendizaje supervisado

Edad	Ingresos	Tiene carro?
24	1'200.000	NO
23	4'500.000	SI
45	1'250.000	SI
32	1'100.000	NO

Factores/atributos/variables independientes,
predictores, explicativos

Dependiente, objetivo,
respuesta, salida

34	3'500.000
----	-----------

¿Cuál es el valor predicho
para una instancia dada?

Aprendizaje no supervisado

Edad	Ingresos
24	1'200.000
23	4'500.000
45	1'250.000
32	1'100.000


Factores/atributos/variables

¿Se puede encontrar alguna
estructura en los datos?







**Aprendizaje
automático**



**Aprendizaje
no supervisado**



**Aprendizaje
supervisado**




Regresión



**Métricas de
Evaluación de la
regresión**




REGRESIÓN



I DON'T TRUST LINEAR REGRESSIONS WHEN IT'S HARDER
TO GUESS THE DIRECTION OF THE CORRELATION FROM THE
SCATTER PLOT THAN TO FIND NEW CONSTELLATIONS ON IT.





- Encontrar modelos, f , que permitan **predecir valores continuos**:
 - **KNN**
 - Regresión lineal
 - Regresión polinómica
 - Árboles de regresión
 - ...
- Valores **numéricos** de la variable o función objetivo
- **Baseline**: medida de evaluación dada por un modelo que predice una medida de tendencia central (e.g. el promedio)



Residuos: diferencia entre los valores reales y los valores predichos

RSS (Residual Sum of Squares): suma de los residuos al cuadrado



ISLR, 2013



Coefficiente de correlación (Pearson: $[-1;1]$): indica la fuerza de la relación lineal entre los predictores y la variable objetivo, que puede ser positiva o negativa

- $|\rho| = 0$ no hay correlación
- $|\rho| = 0.10$ correlación muy débil
- $|\rho| = 0.25$ correlación débil
- $|\rho| = 0.50$ correlación media
- $|\rho| = 0.75$ correlación fuerte
- $|\rho| = 0.90$ correlación muy fuerte
- $|\rho| = 1$ correlación perfecta

$$\rho_{x,y} = \frac{Cov(x,y)}{\sigma_x \sigma_y}$$

Coefficiente de determinación (R^2): indica el porcentaje de la varianza de la variable objetivo que pudo ser explicada por los predictores



- MAE (mean absolute error):

$$\frac{1}{m} \sum_{i=1}^m |h_{\theta}(x_i) - y_i|$$

- MSE (mean square error):


$$\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)^2$$

- RMSE (root mean square error):


$$\sqrt{\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)^2}$$


- R^2 (coeficiente de determinación):

$$1 - \frac{\sum_{i=1}^m (h_{\theta}(x_i) - y_i)^2}{\sum_{i=1}^m (y_i - \bar{y})^2}$$




**Correlación y
causalidad son dos
cosas muy diferentes**







**Aprendizaje
automático**




**Aprendizaje
no supervisado**




**Aprendizaje
supervisado**




Clasificación



Regresión



**Regresión
logística**



KNN




**Métricas de
Evaluación de la
regresión**

grados



CLASIFICACIÓN: REGRESIÓN LOGÍSTICA, KNN



Vamos a enviar un folleto costoso de promoción a nuestra base de clientes, pero no podemos enviarlo a todos los clientes.

Tenemos los datos históricos de los clientes que en el pasado han comprado el producto en cuestión.


Según nuestra base de datos, le enviamos un folleto a:

- ¿Un hombre de 33 años y estrato 5?
- ¿Una mujer de 42 años y estrato 3?
- ¿Una mujer de 28 años y estrato 3?

Género	Edad	Estrato	CLASE
Hombre	52	4	COMPRA
Mujer	28	3	No compra
Hombre	33	5	No compra
Mujer	26	5	COMPRA
Mujer	35	4	No compra
Hombre	51	3	COMPRA
Mujer	28	3	COMPRA




- Encontrar modelos que describan clases para futuras predicciones:
 - KNN
 - Árboles de decisión
 - Regresión logística
 - Redes neuronales
 - ...
- Valores **discretos** de la variable objetivo (categóricos)
- Incluye modelos que no solo clasifican sino que estiman las **probabilidades** de cada clase



http://www.jacmp.org/index.php/jacmp/article/view/5187/html_374



- **Baseline:** (modelo **nulo**) medida de evaluación dada por un clasificador que escoge siempre la clase mayoritaria.
- **Modelo de Bayes:** (modelo **saturado**) el mejor modelo posible con los datos disponibles (modelo generador de los datos).
 - Límite superior de comparación. En general no se conoce.





REGRESIÓN LOGÍSTICA

¿REGRESIÓN LINEAL PARA CLASIFICACIÓN?

Ejemplo: tenemos los datos que relacionan la cantidad de grasas consumidas y el peso de las personas → Regresión

- Si se estima que más de 95kg implica riesgo de diabetes, el problema se convierte en uno de clasificación: 0=a salvo, 1=en peligro
- Una regresión lineal podría ayudar a estimar el límite sobre el cual se estaría en peligro de diabetes
- No se puede interpretar estas predicciones como probabilidades (valores no están en $[0;1]$)
- Poco robusto.



- Algoritmo de **clasificación**, no de **regresión**
- Parte de la idea de la regresión lineal, cuyo resultado es modificado para poder obtener una salida **binaria**: sólo permite distinguir entre 2 clases.
 - Churn vs. Stay
 - Compra vs. No compra
 - Cliente valioso vs. Cliente no valioso
- Se agrega una transformación del resultado de la regresión lineal a partir de una función de distribución acumulativa logística, también conocida como función **logit** o **sigmoide**.

$$f(z) = \frac{e^z}{1+e^z} = \frac{1}{1+e^{-z}}$$



REGRESIÓN LOGÍSTICA

- El modelo pasa de:


$$h_{\Theta}(X) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

a $h_{\Theta}(X) = \mathbf{f}(\mathbf{z}) = \boldsymbol{\sigma}(\theta_0 + \theta_1 x_1 + \dots + \theta_n x_n),$

con $\max(f(z))=1$ y $\min(f(z))=0$

- $\boldsymbol{\sigma}(\mathbf{z})$ es la función **sigmoide** o **logística**
- Se pueden interpretar los valores de $\boldsymbol{\sigma}(\mathbf{z})$ como **probabilidades** de que una instancia con atributos $\mathbf{X}$ pertenezca a la clase $Y=1$:
 $P(\mathbf{Y} = 1 | x_1, \dots, x_n) = p_1(X) = \boldsymbol{\sigma}(\theta_0 + \theta_1 x_1 + \dots + \theta_n x_n)$


$$p_1(X) = \frac{1}{1 + e^{-\Theta^T X}}$$



REGRESIÓN LOGÍSTICA

- Comportamiento:
 - Si $y=1$, queremos que $p_1(X) \approx 1$, luego $\theta^T X \gg 0$
 - Si $y=0$, queremos que $p_1(X) \approx 0$, luego $\theta^T X \ll 0$
- Predicción: se establece un valor de umbral, por ejemplo 0.5
 - Predecir clase 1 si $p_1(X) \geq 0.5$, cuando $\theta^T X \geq 0$
 - Predecir clase 0 de otra manera
- Se puede establecer un umbral diferente si se quiere ser mas o menos robusto en la clasificación


$$p_1(X) = \frac{1}{1 + e^{-\theta^T X}}$$



Wikipedia, 2019




KNN: K-NEAREST NEIGHBORS




KNN (K NEAREST NEIGHBORS): K VECINOS MÁS CERCANOS

- Algoritmo de aprendizaje supervisado para **clasificación** y **regresión**
- **Simple**: asignar la clase o valor agregado de las instancias conocidas que se encuentran mas cerca de la instancia a predecir
- Basado en las **instancias** de aprendizaje, no en un modelo subyacente probabilístico/estadístico
- Aprendizaje **perezoso**: en realidad el algoritmo solo se ejecuta en el momento que se requiere predecir una nueva instancia a partir de una predicción local
- Depende de la definición de una función de **distancia**, que se escogerá según la cantidad y características de las variables independientes



- Ejemplos de medidas de **similitud** o **distancia** utilizadas para encontrar los vecinos más cercanos:


- **Euclidiana:** tamaño del segmento linear que une las dos instancias comparadas.




$$d(\mathbf{p}, \mathbf{q}) = d(\mathbf{q}, \mathbf{p}) = \sqrt{(q_1 - p_1)^2 + (q_2 - p_2)^2 + \dots + (q_n - p_n)^2}$$

$$= \sqrt{\sum_{i=1}^n (q_i - p_i)^2}.$$

- **Manhattan:** basada en una organización en bloques rectilíneos





- **Coseno:** coseno del ángulo entre las dos instancias comparadas → Alta dimensionalidad y **big data**



$$sim(\mathbf{x}, \mathbf{y}) = \cos(\theta_{\mathbf{x}, \mathbf{y}}) = \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} = \frac{\sum_i x_i * y_i}{\sqrt{(\sum_i x_i * x_i) * \sum_i y_i * y_i}}$$




- **Parámetro K:** número de vecinos mas cercanos a considerar para establecer la clase o valor de una nueva instancia



■ **Parámetro K**

- El resultado puede ser drásticamente diferente para diferentes valores de K
- Un valor de K grande suavizará los límites entre clases/valores (alto sesgo, baja varianza)
- Un valor de K pequeño resultará en límites muy flexibles (bajo sesgo, alta varianza)
- El valor de K óptimo se encuentra empíricamente




James et al, ISLR, 2013



KNN – K

Posgrados

- K controla el **overfitting** (sobre-aprendizaje) y el **underfitting** (sub-aprendizaje)
- Modelos **sencillos** (K grande) previenen el overfitting, pero pueden irse hacia el underfitting
- Modelos **complejos** (K pequeños) previenen el underfitting, pero pueden irse hacia el overfitting
- El **K ideal** para todos los casos no existe, depende de cada dataset específico





James et al, ISLR, 2013



En el caso de la utilización de KNN para la regresión las mismas consideraciones aplican


- En el panel izquierdo: se aplica KNN con un valor de $K=1$ (azul) y $K=9$ (rojo)
- En el panel derecho, se puede ver:
 - El valor de RMSE para diferentes valores de K (en verde)
 - El error de la regresión lineal simple (punteada en negro)



James et al, ISLR, 2013



KNN – MALDICIÓN DE LA DIMENSIONALIDAD





KNN – MALDICIÓN DE LA DIMENSIONALIDAD

- KNN puede llegar a ser un muy buen estimador cuando se considera un pequeño número P de variables predictivas
- KNN puede ser inútil cuando P es grande: todo está mucho más lejos cuando se consideran altas dimensiones

Ejemplo: considerar el 10% de los vecinos más cercanos.


En altas dimensiones esos puntos no necesariamente son locales




CLASIFICACIÓN: KNN – REGRESION LOGISTICA

Trabajar en el cuaderno 01-HeartDisease-LogReg+KNN







**Aprendizaje
no supervisado**





**Aprendizaje
supervisado**



**Métricas de
Evaluación de la
clasificación**



**Regresión
logística**



Regresión

**Métricas de
Evaluación de la
regresión**



- Necesidad de evaluar la calidad de los modelos de aprendizaje automático
- Diferentes criterios a tener en cuenta:
 - **Correctitud** de la predicción
 - Simplicidad (parsimonia)
 - Interpretabilidad
 - Tiempo de aprendizaje o de predicción
 - Escalabilidad (importante para Big Data)



- Una **matriz de confusión** evalúa diferentes métricas de correctitud, que permiten establecer **objetivos de negocio**
- Se utilizan dos calificadores para describir cada una de sus casillas:
 - Un calificador de la correctitud de la predicción con respecto a la realidad: Verdadero o Falso
 - Un calificador del tipo de la predicción: Positivo o Negativo, con respecto a cada clase de interés (i.e churn)
- Dependiendo del contexto los tipos de error pueden ser más costosos que otros

		Predicción	
		Churn ^P	No churn ^N
Realidad	Churn ⁺	VP	FN - Tipo II
	No churn ⁻	FP - Tipo I	VN

- La diagonal (en verde) muestra las instancias correctamente clasificadas. Las demás casillas resumen diferentes tipos de error:
 - Tipo I: Falsos positivos
 - Tipo II: Falsos negativos

¿Qué pasa cuando hay más de dos clases?



MÉTRICAS DE CLASIFICACIÓN

- Interpretar el caso de la detección de un email spam

TP, TN:

FP: , consecuencia:

FN: , consecuencia:

- Interpretar el caso del diagnóstico de una enfermedad grave

TP, TN:

FP: , consecuencia:

FN: , consecuencia:

		Predicción	
		Churn ^P	No churn ^N
Realidad	Churn ⁺	VP	FN - Tipo II
	No churn ⁻	FP - Tipo I	VN

- Interpretar el caso de la prospección de clientes de un crédito de consumo (baja aceptación)

TP, TN:

FP: , consecuencia:

FN: , consecuencia:



MÉTRICAS DE CLASIFICACIÓN

- Tasa de correctitud (categorization *accuracy*) = $(VP+VN)/(VP+VN+FP+FN)$
- **Precisión** = $VP / (VP+FP)$: valor de predicción positiva, $P(\text{Real+} | \text{Predicho+})$
- **Recall** (o TPR o **sensibilidad**) = $VP / (VP+FN)$: qué proporción de todos los positivos reales puede identificar como tal, $P(\text{Predicho+} | \text{Real+})$
- Especificidad (o TNR) = $VN / (VN+FP)$: qué proporción de todos los negativos reales puede identificar como tal, $P(\text{Predicho-} | \text{Real-})$


		Predicción	
		Churn P	No churn N
Realidad	Churn +	VP	FN - Tipo II
	No churn -	FP - Tipo I	VN

Medida-F (F-Score): Promedio armónico entre precisión y recall

$$2 * \frac{(\text{Precisión} * \text{Recall})}{(\text{Precisión} + \text{Recall})}$$


MÉTRICAS DE CLASIFICACIÓN

- Coeficiente de concordancia **Kappa**
 - Para datos nominales u ordinales
 - Concordancia entre las predicciones y las clases reales
 - Sustraer el efecto de concordancia por suerte (AC) del valor del **accuracy** (concordancia observada - OA)
 - Valores van de 0 a 1
 - Muy útil sobretodo cuando las clases no están balanceadas
 - Diagnóstico de enfermedades raras
 - Clientes que acepten productos de crédito)
 - $$\text{Kappa} = \frac{OA - AC}{1 - AC}$$



MÉTRICAS DE CLASIFICACIÓN

■ Coeficiente de concordancia **Kappa**

- Para datos nominales u ordinales
- Concordancia entre las predicciones y las clases reales
- Sustrae el efecto de concordancia por suerte (AC) del valor del **accuracy** (concordancia observada - OA)
- Valores van de 0 a 1
- Muy útil sobretodo cuando las clases no están balanceadas
 - Diagnóstico de enfermedades raras
 - Clientes que acepten productos de crédito

		Predicciones		TOTAL
		+	-	
reales	+	10	4	14
	-	3	2	5
TOTAL		13	6	19

OA = 0,63

AC = 0,59

Kappa = 0,11

Accuracy (OA) = $(10+2)/19=0,63$

(AC) = $(13/19 * 14/19) + (6/19 * 5/19) = 0,59$

Kappa = $(OA-AC)/(1-AC) = 0,11$

		Predicciones		TOTAL
		+	-	
reales	+	0	3	3
	-	0	97	97
TOTAL		0	100	100

OA = 0,97

AC = 0,97

Kappa = 0,00

Accuracy (OA) = $(0+97)/100=0,97$

(AC) = $(0/100 * 3/100) + (100/100 * 97/100) = 0,97$

		Predicciones		TOTAL
		+	-	
reales	+	1475	988	2463
	-	556	1981	2537
TOTAL		2031	2969	5000

OA = 0,69

AC = 0,50

Kappa = 0,38

Accuracy (OA) = $(1475+1981)/5000=0,69$

(AC) = $(2031 * 2463 / 5000^2) + (2969 * 2537 / 5000^2) = 0,5$



MÉTRICAS DE CLASIFICACIÓN

TALLER: CÁLCULO DE MÉTRICAS

Los clientes son usualmente categorizados en perfiles de comportamiento de compra de productos o servicios.

Suponga que se creó un modelo para clasificar los clientes en una de 4 clases posibles (esporádico, fiel, parcial y promocional), cuya matriz de confusión presentamos a continuación:

	PREDICCIÓN				
REAL	Esporádico	Fiel	Parcial	Promocional	Total
Esporádico	61	8	1	0	70
Fiel	0	56	17	0	73
Parcial	0	0	15	0	15
Promocional	0	0	0	24	24
Total	61	64	33	24	182

En **grupos de tres o cuatro personas** calcule las métricas de evaluación de un modelo de clasificación cuyos resultados están reflejados en la tabla anterior



TALLER DE CLASIFICACIÓN: CÁLCULO DE MÉTRICAS

- Trabajar en grupos de exactamente 3 o 4 estudiantes sobre la tarea para posterior socialización.
- Indicar los integrantes de cada grupo.
- Entregar a más tardar el día sábado de 5 de abril de 2025




MÉTRICAS DE CLASIFICACIÓN (ROC AUC, LOG-LIKELIHOOD, DEVIANCE, AIC, ENTROPÍA, BIC)

Evaluación de modelos **probabilísticos** de clasificación:

- Métricas que permiten comparar modelos con resultados **probabilísticos** como regresión logística, árboles de decisión, KNN, etc., sobre el mismo dataset
- Insensibles a diferentes costos del error de las diferentes clases



- **ROC AUC** (Area under the Curve)
 - **Receiver Operating Curve:** Curva de la tasa de los verdaderos positivos (recall o sensibilidad) contra la de los falsos positivos ($1 - \text{especificidad}$)
 - Clasificadores binarios
 - Se hace variar el umbral de definición de predicción positiva y negativa (**operating point**)
 - Permite establecer compromisos entre los dos tipos de errores




Wikipedia.org




■ **ROC AUC** (Area under the Curve)

- **Receiver Operating Curve:** Curva de la tasa de los verdaderos positivos (recall o sensibilidad) contra la de los falsos positivos (1 – especificidad)
- Clasificadores binarios
- Se hace variar el umbral de definición de predicción positiva y negativa
- Permite establecer compromisos entre los dos tipos de errores



■ **ROC AUC** (Area under the Curve)

- **Receiver Operating Curve:** Curva de la tasa de los verdaderos positivos (recall o sensibilidad) contra la de los falsos positivos ($1 - \text{especificidad}$)
- Clasificadores binarios
- Se hace variar el umbral de definición de predicción positiva y negativa
- Permite establecer compromisos entre los dos tipos de errores




Wikipedia.org



■ **ROC AUC** (Area under the Curve)

- **Receiver Operating Curve:** Curva de la tasa de los verdaderos positivos (recall o sensibilidad) contra la de los falsos positivos (1 – especificidad)
- Clasificadores binarios
- Se hace variar el umbral de definición de predicción positiva y negativa
- Permite establecer compromisos entre los dos tipos de errores
- $TPR(T) = \int_T^\infty f_{TP}(x)dx$, $FPR(T) = \int_T^\infty f_{FP}(x)dx$.



- Trabajar en el notebook 02-Confusion_Matrix - Probabilistic Metrics



- *Introduction to Statistical Learning with Applications in Python (ISLR)*, G. James, D. Witten, T. Hastie & R. Tibshirani, 2023
- *KROESE, Dirk P.; BOTEV, Zdravko; TAIMRE, Thomas. Data science and machine learning: mathematical and statistical methods. Chapman and Hall/CRC, 2019.*
- *Data Mining (4th Edition)*, Ian Witten, Eibe Frank, Mark A. Hall & Christopher J. Pal, Elsevier, 2016
- *Machine Learning*, Tom M. Mitchell, McGraw-Hill, 1997
- *Data Science for Business*, Foster Provost & Tom Fawcett, O'Reilly, 2013
- *False positives, false negatives and confusion matrices*, Carlos Guestrin, 2017

