

MAQUINAS DE VECTORES DE SOPORTE (SVM)

OBJETIVOS DE APRENDIZAJE

- **[OT1]** Identificar problemáticas que se puedan resolver a partir de modelos de aprendizaje supervisado, ya sea de clasificación o de regresión.
- **[OT2]** Aplicar modelos de aprendizaje supervisado a conjuntos de datos para responder a preguntas de negocio involucrando modelos de aprendizaje supervisado, utilizando el lenguaje Python.
- **[OT5]** Establecer los mejores valores de los parámetros para modelos de aprendizaje supervisado

SVM: Hiperplano de separación

Una **Máquina de Soporte Vectorial** es un modelo de aprendizaje supervisado utilizado para:

- Clasificación (binaria o multiclase)
- Regresión (SVR)

Su objetivo principal es encontrar un **hiperplano** que **separe los datos** de manera óptima.



SVM: Hiperplano de separación

- Considere un conjunto de datos separable en dos clases con una línea (en 2D), un plano (en 3D), o un hiperplano (en más de 3D).
- El objetivo de SVM es encontrar ese hiperplano que mejor separa las clases.

$$\{x \in \mathbb{R}^n : f(x) = w^T x + b = 0\}$$

- w es el vector de pesos, x es el vector de características y b es el sesgo o intercepto.

$$f(x) = \text{sign}(w^T x + b)$$




SVM: Hiperplano de separación

Cuando se presenta un dato de prueba, lo clasificamos como positivo o negativo según el lado del hiperplano en el que se encuentre.


$$w^T x + b \geq 0 \text{ cuando } y_n = +1$$

$$w^T x + b < 0 \text{ cuando } y_n = -1$$



$$y_n(w^T x + b) \geq 0$$

- denota +1
- denota -1




Cualquier plano funciona ...
pero, ¿cuál es el mejor?

SVM: Hiperplano de separación

Posgrados


- **Margen Máximo:** SVM no solo busca cualquier hiperplano; busca el que maximiza el margen entre las dos clases.
- **Un margen amplio garantiza capacidad de generalización**



ISLR

SVM: Hiperplano de separación y vectores de soporte

- **Vectores de Soporte:** Son los datos que están más cercanos al hiperplano de separación.
- Estos datos son críticos para determinar la posición y orientación del hiperplano.




ISLR

SVM: Formulación matemática

Consideremos una función: $f: \mathbb{R}^D \rightarrow \mathbb{R}$, definida por $f(x) = w^T x + b$ donde $w \in \mathbb{R}^D$ y $b \in \mathbb{R}$ definimos el hiperplano separador como $\{x \in \mathbb{R}^D : f(x) = 0\}$. Para dos puntos x_a y x_b sobre el hiperplano

$$f(x_a) - f(x_b) = w^T x_a + b - (w^T x_b + b) = w^T (x_a - x_b) = 0$$



[Mathematics for machine learning](#)

Al entrenar un clasificador, necesitamos asegurar que los ejemplos con etiquetas positivas estén en el lado positivo del hiperplano

$$w^T x_a + b \geq 0 \text{ cuando } y_n = +1$$

Similarmente con las etiquetas negativas


$$w^T x_a + b < 0 \text{ cuando } y_n = -1$$

Estas dos ecuaciones son equivalentes a

$$y_n(w^T x_a + b) \geq 0$$

SVM: Formulación matemática

Ahora vamos a introducir el concepto de margen: la distancia al hiperplano de separación. Considere el hiperplano $w^T x + b$ y el punto x_a



[Mathematics for machine learning](#)

Queremos calcular la distancia $r > 0$ del punto x_a al hiperplano. Esto se hace considerando la proyección ortogonal, x'_a , se puede mostrar en ese caso que

$$x_a = x'_a + r \frac{w}{\|w\|}$$

Ahora bien, queremos los datos positivos mas allá de la distancia r , lo cual podemos formular como

$$y_n(w^T x_a + b) \geq r$$

SVM: Formulación matemática

De lo anterior obtenemos la primera formulación del problema de optimización

$$\begin{aligned} & \max_{w,b,r} && r \\ & \text{sujeto a} && y_n(w^T x_a + b) \geq r, \|w\| = 1, r > 0 \end{aligned}$$

De la figura podemos ver que $w^T x'_a + b = 0$. Sustituyendo $x_a = x'_a + r \frac{w}{\|w\|}$ tenemos


$$w^T \left(x_a - r \frac{w}{\|w\|} \right) + b = 0$$

De donde $w^T x_a + b - r \frac{w^T w}{\|w\|} = 0$ y de aquí $r = \frac{1}{\|w\|}$, dado que $w^T w = \|w\|^2$. Luego

nuestro problema de optimización se convierte en $\max_{w,b} \frac{1}{\|w\|}$ o
sujeto a $y_n(w^T x_a + b) \geq 1$

equivalentemente $\min_{w,b} \frac{1}{2} \|w\|^2$
sujeto a $y_n(w^T x_a + b) \geq 1$

Esta última formulación se conoce como *hard margin SVM*.




[Mathematics for machine learning](#)

SVM: Formulación matemática

Si los datos no son linealmente separables podemos relajar la formulación dura. Para ello se introducen las denominadas variables de holgura ξ que permiten datos en el margen o en el lado equivocado del hiperplano.

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n \\ \text{sujeto a} \quad & y_n(w^T x_n + b) \geq 1 - \xi_n \\ & \xi_n \geq 0 \end{aligned}$$



Esta última formulación se conoce como *soft margin SVM*, y el parámetro C actúa como un parámetro de regularización. Un valor grande de C corresponde a una menor regularización.

[Mathematics for machine learning](#)

SVM: Formulación matemática

Vamos a considerar ahora una formulación alternativa del problema de optimización primal:

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n \\ \text{sujeto a} \quad & y_n(w^T x_n + b) \geq 1 - \xi_n \\ & \xi_n \geq 0 \end{aligned}$$

Para ello definimos el lagrangiano:

$$\mathcal{L}(w, b, \xi, \alpha, \gamma) = \frac{1}{2} \|w\|^2 + C \sum_{n=1}^N \xi_n - \sum_{n=1}^N \alpha_n (y_n(w^T x_n + b) - 1 + \xi_n) - \sum_{n=1}^N \gamma_n \xi_n$$

derivamos con respecto a las variables primales w, b, ξ , y después de una buena dosis de cálculos se llega a la formulación dual:

SVM: Formulación matemática

Problema dual (negativo) SVM:

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j (x_i^T x_j) - \sum_{i=1}^N \alpha_i$$

sujeto a $\sum_{i=1}^N y_i \alpha_i = 0$

Donde $0 \leq \alpha_i \leq C$, para todo $i = 1, \dots, N$.


NOTA: El siguiente resultado obtenido de igualar a cero la derivada respecto a w del Lagrangiano (teorema del representador) explica el nombre de "máquina de vectores de soporte".

$$w = \sum_{i=1}^N \alpha_i y_i x_i$$

Los x_i cuyos parámetros correspondientes $\alpha_i > 0$, son los únicos que contribuyen a la solución w se denominan vectores de soporte, ya que "soportan" el hiperplano.

SVM: Formulación matemática


- Vectores de soporte $\alpha_i \in (0,1)$, en los márgenes (rodeados con un círculo verde en la figura) y están correctamente clasificados.
- Vectores de soporte $\alpha_i = 1$, que pueden o no estar correctamente clasificados.
- Vectores que no son de soporte $\alpha_i = 0$, se encuentran fuera de los márgenes.
 - Todos estos puntos están correctamente clasificados.



DSML

SVM: Kernels

Sabemos que si el conjunto de entrenamiento no es linealmente separable, se pueden agregar variables de holgura ξ_i para permitir la clasificación incorrecta de datos atípicos o ruidosos (soft margin).



SVM: Kernels

En lugar de usar el soft margin, se usa del problema dual SVM:


$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j (x_i^T x_j) - \sum_{i=1}^N \alpha_i \\ \text{sujeto a} \quad & \sum_{i=1}^N y_i \alpha_i = 0 \end{aligned}$$

- Aquí solo importan los **productos internos entre datos** $x_i^T x_j$
- Podemos reemplazar ese producto por uno entre **representaciones de características** $\phi(x)$
- Esto permite separar:
 - El **modelo** (SVM)
 - La **representación** $\phi(x)$


SVM: Kernels

- Si $\phi(x)$ es **no lineal**, el SVM puede clasificar datos **no linealmente separables**.
- En lugar de calcular $\phi(x)$ se usa un **kernel** $k(x_i, x_j)$ que mide similitud.
- Un **kernel** define implícitamente un espacio de características de **alta dimensión**.
- Los kernels mas populares son:
 - Kernel Lineal: $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i \cdot \mathbf{x}_j$
 - Kernel Polinomial: $K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i \cdot \mathbf{x}_j + c)^d$
 - Kernel Gaussiano (RBF): $K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$


SVM: Kernels




(a) SVM with linear kernel



(b) SVM with RBF kernel




(c) SVM with polynomial (degree 2) kernel



(d) SVM with polynomial (degree 3) kernel

[Mathematics for machine learning](#)


Si los datos son separables todo funciona bien



Pero si el conjunto de datos tiene una frontera diferente




Podemos llevar los datos a un espacio de dimensión más alta





SVM: Kernels

SVM puede aplicar el "truco del kernel", que proyecta los datos en un espacio de mayor dimensión donde sí pueden ser linealmente separables.



SVM: Kernels

Otra perspectiva



DSML

SVM: consideraciones finales

SVM aún compite con otros modelos del estado del arte, con garantías teóricas sólidas.

El truco del kernel:

- La función kernel solo requiere una multiplicación por dimensión de entrada, lo que puede generar importantes ahorros computacionales.
- No es necesario que los datos originales estén representados como datos multivariados de valor real (e.g. conjuntos, sucesiones, cadenas, ...)

SVM: Kernels

Trabajar en los cuadernos:
SVM_intro_toy_examples y 2_SVM-sklearn-
Class-Reg

Referencias

1. Gareth, J., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An Introduction to Statistical Learning: with Applications in Python.
2. Kroese, D. P., Botev, Z., & Taimre, T. (2019). Data science and machine learning: mathematical and statistical methods. Chapman and Hall/CRC.
3. Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). Mathematics for machine learning. Cambridge University Press.
4. Müller, A. C., & Guido, S. (2016). Introduction to machine learning with Python: a guide for data scientists. "O'Reilly Media, Inc".