

MAQUINAS DE VECTORES DE SOPORTE (SVM)

¿Qué son las Máquinas de Soporte Vectorial (SVM)?

- Las Máquinas de Soporte Vectorial (SVM, por sus siglas en inglés) son un poderoso algoritmo de aprendizaje supervisado utilizado principalmente para problemas de clasificación, aunque también pueden ser adaptadas para regresión.
- Su objetivo principal es encontrar un "hiperplano" en un espacio de características de alta dimensionalidad que divida los datos en diferentes clases con el margen más amplio posible.


SVM: Hiperplano de separación

- Imagine que tiene un conjunto de datos separable en dos clases con una línea (en 2D), un plano (en 3D), o un hiperplano (en más de 3D).
- El objetivo de SVM es encontrar ese hiperplano que mejor separa las clases.

$$\{x \in \mathbb{R}: f(x) = w^T x + b = 0\}$$


- w es el vector de pesos, x es el vector de características y b es el sesgo o intercepto.

- denotes +1
- denotes -1




SVM: Hiperplano de separación

Cuando se presenta un dato de prueba, lo clasificamos como positivo o negativo según el lado del hiperplano en el que se encuentre.




SVM: Hiperplano de separación

- **Margen Máximo:** SVM no solo busca cualquier hiperplano; busca el que maximiza el margen entre las dos clases.
- Un margen amplio garantiza capacidad de generalización





SVM: Hiperplano de separación y los vectores de soporte


Vectores de Soporte: Son los puntos de datos que están más cercanos al hiperplano de separación. Estos puntos son críticos para determinar la posición y orientación del hiperplano.



SVM: Formulación matemática



Cómo calcular M en términos de w y b ?



$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq M/2$$

$$r = \frac{y_s(\mathbf{w}^T \mathbf{x}_s + b)}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

$$M = 2r = \frac{2}{\|\mathbf{w}\|}$$

SVM: Formulación matemática

$$\begin{aligned}
 & \max_{\mathbf{w}, b, r} \quad \underbrace{r}_{\text{margin}} \\
 & \text{subject to} \quad \underbrace{y_n(\langle \mathbf{w}, \mathbf{x}_n \rangle + b) \geq r}_{\text{data fitting}}, \underbrace{\|\mathbf{w}\| = 1}_{\text{normalization}}, \quad r > 0, \\
 \\
 & \min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2 \\
 & \text{subject to} \quad y_n(\langle \mathbf{w}, \mathbf{x}_n \rangle + b) \geq 1 \quad \text{for all } n = 1, \dots, N.
 \end{aligned}$$

SVM: Formulación matemática

Margen: El margen, que SVM intenta maximizar, es dado por la expresión:

$$\text{Margen} = \frac{2}{\|\mathbf{w}\|}$$

SVM maximiza este margen minimizando $\|\mathbf{w}\|$, sujeto a las restricciones de clasificación anteriores.

Calcular $\mathbf{w}$ y b tal que $M = \frac{2}{\|\mathbf{w}\|}$ es máximo
para todo $(\mathbf{x}_i, y_i), i=1..n$: $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$

SVM: Formulación matemática

Problema de Optimización Primal

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

Sujeto a

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 \quad \text{para todo } i$$

Problema de Optimización Dual: Utilizando multiplicadores de Lagrange, el problema se transforma en

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j)$$


Sujeto a

$$\sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0$$

Donde los α_i son los multiplicadores de Lagrange.

SVM: Formulación matemática

- Puntos para los que $\alpha_i \in (0,1)$.
Vectores de soporte en los márgenes (rodeados con un círculo verde en la figura) y están correctamente clasificados.
- Puntos para los que $\alpha_i = 1$.
Vectores de soporte, que pueden o no estar correctamente clasificados.
- Puntos para los que $\alpha_i = 0$.
Vectores que no son de soporte, se encuentran fuera de los márgenes. Todos estos puntos están correctamente clasificados.




DSML

SVM: Formulación matemática

¿Qué ocurre si el conjunto de entrenamiento no es linealmente separable?

Se pueden agregar variables de holgura ξ_i para permitir la clasificación incorrecta de ejemplos difíciles o ruidosos, resultando en un margen llamado "suave" (soft margin).



SVM: Formulación matemática

El nuevo problema:


Calcular $\mathbf{w}$ y b tal que $\Phi(\mathbf{w}) = \mathbf{w}^T \mathbf{w} + C \sum \xi_i$ sea máximo

Para todo $(\mathbf{x}_i, y_i), i=1..n$: $y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$

El parámetro C puede verse como una forma de controlar el sobreajuste: realiza un "intercambio" entre la importancia relativa de maximizar el margen y ajustar los datos de entrenamiento.

SVM: frontera no lineal


Si los datos son separables todo funciona bien



Pero si el conjunto de datos tiene una frontera diferente




¿Que pasaría si llevamos los datos a un espacio de dimensión más alta?



SVM: frontera no lineal



Idea general

En casos donde los datos no son linealmente separables, SVM puede aplicar el "truco del kernel", que proyecta los datos en un espacio de mayor dimensión donde sí pueden ser linealmente separables.



SVM: frontera no lineal

Otra perspectiva



DSML

SVM: función Kernel

En lugar de calcular explícitamente la proyección en un espacio de mayor dimensión, SVM usa funciones kernel

$$K(x_i, x_j)$$

que calculan el producto punto en ese espacio sin necesidad de hacer la transformación directa. Ejemplos de funciones kernel:

- Kernel Lineal: $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i \cdot \mathbf{x}_j$
- Kernel Polinomial: $K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i \cdot \mathbf{x}_j + c)^d$
- Kernel Gaussiano (RBF): $K(\mathbf{x}_i, \mathbf{x}_j) = \exp \left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2} \right)$

SVM aún compite con otros modelos del estado del arte, con garantías teóricas sólidas.

El truco del kernel:

- La función kernel solo requiere una multiplicación por dimensión de entrada, lo que puede generar importantes ahorros computacionales.
- No es necesario que los datos originales ya estén representados como datos multivariados de valor real (e.g. conjuntos, sucesiones, cadenas, ...)

Referencias

1. Gareth, J., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An Introduction to Statistical Learning: with Applications in Python.
2. Kroese, D. P., Botev, Z., & Taimre, T. (2019). Data science and machine learning: mathematical and statistical methods. Chapman and Hall/CRC.
3. Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). Mathematics for machine learning. Cambridge University Press.
4. Müller, A. C., & Guido, S. (2016). Introduction to machine learning with Python: a guide for data scientists. "O'Reilly Media, Inc".
5. Diapositivas de clase
6. Guías de lectura
7. Cuadernos Jupyter (Intu)