


APRENDIZAJE SUPERVISADO




Anibal Sosa, PhD




AGENDA



Protocolos



**Aprendizaje
supervisado**



**Sobre aprendizaje
(Overfitting)**



OBJETIVOS DE APRENDIZAJE


- RA1. Reconocer y resolver problemas de clasificación y de regresión,
- RA3. Implementar algoritmos en Python para el entrenamiento y la evaluación de modelos de analítica, utilizando las métricas pertinentes al tipo de problema que solucionan
 - Aplicar modelos de IA a conjuntos de datos, para responder a preguntas de negocio involucrando modelos de aprendizaje supervisado.
 - Comparar modelos de aprendizaje supervisado con respecto a métricas de ajuste, utilizando diferentes protocolos de evaluación



OVERFITTING Y PROTOCOLOS DE EVALUACIÓN

SESGO/ VARIANZA

- **Sesgo** (bias): que tan lejos está el modelo de la verdad
- **Varianza**: Qué tanto varían los datos de la predicción para una misma instancia



Domingo, 2012

$$Err(x) = \underbrace{\left(E[\hat{f}(x)] - f(x) \right)^2}_{\text{Sesgo}^2} + \underbrace{E[\hat{f}(x) - E[\hat{f}(x)]]^2}_{\text{Varianza}} + \underbrace{\sigma_e^2}_{\text{Error irreducible}}$$


Promedio del modelo
Verdad
Promedio del modelo

cada resultado del modelo



SESGO / VARIANZA


- Ambos son fuente de error
- Se debe determinar un **compromiso** entre ambos tipos de error
- Parámetros de los modelos controlan la complejidad



Bias / Variance



SOBRE APRENDIZAJE (OVERFITTING)




Overfitting in trading

- **Sobre aprendizaje:** Los modelos aprenden a describir los errores aleatorios o el “ruido” del conjunto de entrenamiento.
- Ocurre cuando un modelo se vuelve excesivamente **complejo**




SOBRE APRENDIZAJE (OVERFITTING)

Regresión



Clasificación



Overfitting


¿Cómo es el sesgo y la varianza de estos modelos?

- La **complejidad** de un modelo debe ajustarse de tal manera que permita la **generalización**, al utilizarse con datos que no haya conocido durante el proceso de entrenamiento
- Principio de **parsimonia** (Occam's Razor): la mejor explicación es la más simple → preferir los modelos más sencillos con menos suposiciones



SOBRE APRENDIZAJE (OVERFITTING)

- Los modelos tienden a ajustarse al conjunto de datos usado para su aprendizaje → el **error de entrenamiento** es un mal estimador
- Queremos encontrar la complejidad del modelo que nos permita minimizar el **error de test**




Overfitting



SOBRE APRENDIZAJE (OVERFITTING)

- Los modelos tienden a ajustarse al conjunto de datos de entrenamiento → el **error de entrenamiento** es un mal estimador
- Queremos encontrar la complejidad del modelo que nos permita minimizar el **error de prueba**




ISLR, 2014


Double Descent



Protocolos



**Aprendizaje
supervisado**



**Sobre aprendizaje
(Overfitting)**




PROTOSCOLOS DE EVALUACIÓN

- Aplican para modelo de aprendizaje supervisado en general.
- Permiten:
 - Definir los mejores valores de los hiper parámetros de los modelos (**flexibilidad**).
 - Evaluar la capacidad de **generalización** del modelo.
 - Comparar el **error de entrenamiento** y el **error de test**.
 - Evitar el sesgo causado por la **subestimación del error** al evaluar con el mismo set de entrenamiento.
 - Establecer un compromiso entre sesgo y varianza, para reducir el **sobre aprendizaje** y encontrar un modelo con buenas **capacidades predictivas**.



PROTOSCOLOS DE EVALUACIÓN





Cross - validation



PROTOSCOLOS DE EVALUACIÓN

- **Holdout:** particionar el conjunto de datos en dos:
 - **Conjunto de entrenamiento (*train*):** con el que aprende el algoritmo de clasificación
 - **Conjunto de validación (*test*):** separado al comienzo del proceso y no considerado en el aprendizaje
 - **Aleatoriedad** del particionamiento
 - **Compromiso:** entre más datos mejor el aprendizaje, y la evaluación
- **Repeated holdout:** repetir el procedimiento de evaluación y agregar las métricas de



Validación Cruzada (Cross-Validation - CV)

Es una técnica de **remuestreo** que nos permite obtener una estimación más robusta y fiable del rendimiento de un modelo



Validación Cruzada (Cross-Validation - CV)


- **Estimación del Rendimiento del Modelo:** Proporciona una medida más precisa de cómo se generalizará el modelo a nuevos datos.
- **Selección de Modelos:** Permite comparar de manera justa el rendimiento de diferentes algoritmos.
- **Ajuste de Hiperparámetros (Hyperparameter Tuning):** Ayuda a encontrar la mejor combinación de hiperparámetros para un modelo.



PROTOCOLOS DE EVALUACIÓN

■ **K-fold cross-validation:**

- Particionar el conjunto de datos en K conjuntos disjuntos del mismo tamaño
- K - 1 partes se usan para entrenamiento, una parte se usa para el test
- Se repite el proceso K veces
- Se agregan las métricas de evaluación




Sebastian Raschka, 2015



Validación Cruzada de K-Pliegues (K-Fold CV)


1. El conjunto de datos se divide aleatoriamente en K subconjuntos.
2. Se realizan K iteraciones.
3. Se entrena el modelo y se evalúa su rendimiento.
4. El rendimiento final del modelo es el promedio de las métricas de rendimiento de las K iteraciones.




K-Fold Estratificado (Stratified K-Fold)

- **Ideal** para problemas de clasificación con clases desbalanceadas.
- **Crea** los pliegues, y se asegura de que cada uno tenga aproximadamente la misma proporción de muestras de cada clase.

Stratified K-Fold
Cross Validation
(K=5)




Class Distributions



PROTOCOLOS DE EVALUACIÓN

- **K-fold cross-validation**,
Escogencia del K:
 - Permite balancear entre sesgo y varianza
 - **LOOCV** (Leave One Out Cross-Validation): conjuntos unitarios
 - Se estima que los mejores resultados se obtienen con un valor de K entre 5 y 10




Sebastian Raschka, 2015



Leave-One-Out Cross-Validation (LOOCV)

- Es un caso extremo de K-Fold CV donde $K = n$, el número de muestras.
- En cada iteración, se entrena el modelo con $n - 1$ muestras y se valida con la muestra restante. Esto se repite n veces



PROTOSCOLOS DE EVALUACIÓN

■ Bootstrapping:

- Consideración de varios conjuntos de entrenamiento/test utilizando muestreo con remplazo
- Por lo general, los muestreos son del mismo tamaño del conjunto original
- Muy buen estimador de los parámetros, pero no de las métricas de calidad de los modelos (sesgo causado por el promedio de observaciones distintas ($0.632 \cdot N$))

Original Dataset

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
-------	-------	-------	-------	-------	-------	-------	-------	-------	----------

Bootstrap 1

x_8	x_6	x_2	x_9	x_5	x_8	x_1	x_4	x_8	x_2
-------	-------	-------	-------	-------	-------	-------	-------	-------	-------

Bootstrap 2

x_{10}	x_1	x_3	x_5	x_1	x_7	x_4	x_2	x_1	x_8
----------	-------	-------	-------	-------	-------	-------	-------	-------	-------

Bootstrap 3

x_6	x_5	x_4	x_1	x_2	x_4	x_2	x_6	x_9	x_2
-------	-------	-------	-------	-------	-------	-------	-------	-------	-------

Sebastian Raschka, 2015




PROTOSCOLOS DE EVALUACIÓN

■ Set de validación vs set de test:

- Separación de un set de datos de **test** para evaluación final del modelo escogido
- **Overfitting** si se calibran los modelos con el mismo set de test




Toward data science




Shuffle & Split (Mezcla y División)

- Repeated Random Sub-sampling o Monte Carlo Cross-Validation. Crea divisiones independientes y aleatorias en cada iteración
 - Mezclar (Shuffle)
 - Dividir (Split)




Los **hiperparámetros** son parámetros del modelo que no se aprenden durante el entrenamiento, sino que se establecen antes (e.g., la tasa de aprendizaje en el descenso de gradiente)



EJEMPLO DE PROTOCOLOS

- **S5-Protocolos-Ejemplo**





Universidad

icesi

REFERENCIAS

Posgrados

- *Introduction to Statistical Learning with Applications in R (ISLR)*, G. James, D. Witten, T. Hastie & R. Tibshirani, 2014
- *Machine Learning with R*, Brett Lantz, Packt Publishing, 2015
- *Machine Learning*, Tom M. Mitchell, McGraw-Hill, 1997

