



Comenzado el

martes, 14 de octubre de 2025, 20:36

Estado

Finalizado

Finalizado en

martes, 14 de octubre de 2025, 21:47

Tiempo empleado

1 hora 10 minutos

Puntos

5,48/5,50

Calificación

4,98 de 5,00 (99,55%)

Pregunta 1

[Marcar pregunta](#)

Finalizado

Se puntúa 0,50 sobre 0,50

Sin saber nada del contexto de aplicación de un problema de clasificación dado, y considerando la tabla siguiente, ¿Qué modelo de clasificación escogería? Explique brevemente su respuesta

Métrica Protocolo de evaluación	% error		Kappa	
	Training set	5-fold CV	Training set	5-fold CV
Modelo 1	15.3 %	16.3%	0.58	0.54
Modelo 2	22.8%	60.1%	0.65	0.25
Modelo 3	28.5%	28.9%	0.12	0.10
Modelo 4	15.7%	16.1%	0.60	0.56

Teniendo en cuenta las métricas presentes, escogería el modelo 4 ya que presenta mayor precisión y generalización. Si visualizamos las métricas como el entrenamiento y validación cruzada de error tienen un mejor porcentaje de variabilidad en las pruebas lo que me ayuda a tener una consistencia y generalización entre los datos de entrenamiento y prueba ya que tiene un 0.4 puntos de diferencia, esto nos permite que cuando se realiza una validación del factor Kappa con la validación cruzada encuentre un mejor balance en los datos y mejorando considerablemente la predicción ya que permite la discriminación de estos y si hablamos de clases desbalanceadas lo hará aun mejor ya que tiene en cuenta todas estas distribuciones lo que nos indica que nos ayuda a tener mayor poder de generalización.

El **Modelo 1** o el **Modelo 4**, presentan un buen balance entre precisión y consistencia (bajo % de error y valores altos de Kappa) tanto en el conjunto de entrenamiento como en la validación cruzada. Entre los dos, el **Modelo 4** es ligeramente preferible, ya que presenta un % de error más bajo y un coeficiente Kappa ligeramente superior en validación cruzada

Comentario:

Pregunta 2

[Marcar pregunta](#)**Correcta**

Se puntúa 0,40 sobre 0,40

Considerando ensambles de árboles de decisión, empareje las opciones mas adecuadas

Parte de una muestra con repetición de los registros para calcular cada modelo, pero difiere en los particionamientos en cada nodo

Random Forest



Se puede paralelizar fácilmente

Bagging y Random Forest



Cada árbol desarrollado puede tener pesos diferentes

Boosting



Utiliza predictores débiles, evalúa las predicciones del modelo y aumenta la ponderación de las muestras que presentan un error más significativo.

Boosting



Respuesta correcta

La respuesta correcta es: Parte de una muestra con repetición de los registros para calcular cada modelo, pero difiere en los particionamientos en cada nodo → Random Forest, Se puede paralelizar fácilmente → Bagging y Random Forest, Cada árbol desarrollado puede tener pesos diferentes → Boosting, Utiliza predictores débiles, evalúa las predicciones del modelo y aumenta la ponderación de las muestras que presentan un error más significativo. → Boosting

Pregunta 3

[Marcar pregunta](#)

Correcta

Se puntúa 0,40 sobre 0,40

Emparaje las opciones mas adecuadas con respecto a los modelos de árboles de decisión

Para un número elevado de registros de entrenamiento, si el número de variables independientes a considerar es alto

El modelo es indiferente



Si el número de hojas terminales del árbol es elevado

El modelo es propenso al overfitting



Si la profundidad del árbol es muy baja

El modelo es propenso al underfitting



Si el árbol se deja crecer completamente

El modelo es propenso al overfitting



Para un número elevado de registros de entrenamiento, si el número de categorías de la variable objetivo es alto

El modelo es indiferente



Respuesta correcta

La respuesta correcta es: Para un número elevado de registros de entrenamiento, si el número de variables independientes a considerar es alto → El modelo es indiferente, Si el número de hojas terminales del árbol es elevado → El modelo es propenso al overfitting, Si la profundidad del árbol es muy baja → El modelo es propenso al underfitting, Si el árbol se deja crecer completamente → El modelo es propenso al overfitting, Para un número elevado de registros de entrenamiento, si el número de categorías de la variable objetivo es alto → El modelo es indiferente

Pregunta 4

[Marcar pregunta](#)**Correcta**

Se puntúa 0,25 sobre 0,25

Con respecto a los protocolos de evaluación, ¿Cuáles de las siguientes afirmaciones son verdaderas?

Seleccione una o más de una:

- ☐ a. Utilizar el error de entrenamiento para estimar la capacidad de predicción de un modelo de aprendizaje supervisado es una buena práctica
- ☒ b. El protocolo de K-fold cross validation da una buena estimación de las métricas de ajuste de un modelo de aprendizaje supervisado ✓
- ☒ c. El error de prueba (test) es un buen estimador de la capacidad de generalización de un modelo de aprendizaje supervisado ✓
- ☒ d. Es preferible seguir un protocolo de hold-out a uno que evalúe un clasificador a partir del conjunto de entrenamiento ✓

Respuesta correcta

Las respuestas correctas son: El error de prueba (test) es un buen estimador de la capacidad de generalización de un modelo de aprendizaje supervisado, El protocolo de K-fold cross validation da una buena estimación de las métricas de ajuste de un modelo de aprendizaje supervisado, Es preferible seguir un protocolo de hold-out a uno que evalúe un clasificador a partir del conjunto de entrenamiento

Pregunta 5

[Marcar pregunta](#)**Correcta**

Se puntúa 0,20 sobre 0,20

Si tengo que evaluar un modelo de aprendizaje supervisado muy complejo sobre un gran volumen de datos (millones de registros y cientos de atributos), ¿qué protocolo sería el mas adecuado para utilizar?

Seleccione una:

- ☐ a. Evaluar sobre el conjunto de entrenamiento
- ☒ b. Hold-Out ✓
- ☐ c. 15-Fold Cross-Validation
- ☐ d. LOOCV

Respuesta correcta

La respuesta correcta es: Hold-Out

Pregunta 6

[Marcar pregunta](#)**Correcta**

Se puntúa 0,20 sobre 0,20

El sobre-aprendizaje tiene mayor posibilidad de ocurrir cuando:

Seleccione una o más de una:

- ☐ a. El tamaño del conjunto de entrenamiento es muy grande
- ☒ b. El modelo presenta un error de entrenamiento (train) muy bajo, pero error de prueba (test) alto ✓
- ☐ c. Se usan muchos datos en el conjunto de prueba (test)
- ☒ d. El modelo es demasiado complejo ✓

Respuesta correcta

Las respuestas correctas son: El modelo es demasiado complejo, El modelo presenta un error de entrenamiento (train) muy bajo, pero error de prueba (test) alto

Pregunta 7

[Marcar pregunta](#)

Correcta

Se puntúa 0,40 sobre 0,40

Considere esta tabla de comparación de métricas de modelos entrenados sobre los mismos datos:

Métrica	% error		Kappa	
	Training set	10-fold CV	Training set	10-fold CV
Modelo 1	5.7%	7.1%	0.60	0.50
Modelo 2	15.3%	16.3%	0.33	0.24
Modelo 3	22.8%	58.4%	0.36	0.23
Modelo 4	28.3%	28.5%	0.11	0.10

Empareje las afirmaciones que le parezcan más adecuadas para cada modelo, basándose en la información de la tabla anterior.

Modelo 4	Está en underfitting	✓
Modelo 2	No está en overfitting, pero puede estar underfitting	✓
Modelo 3	Está en overfitting	✓
Modelo 1	Tiene el mejor balance entre overfitting y underfitting	✓

Respuesta correcta

La respuesta correcta es: Modelo 4 → Está en underfitting, Modelo 2 → No está en overfitting, pero puede estar underfitting, Modelo 3 → Está en overfitting, Modelo 1 → Tiene el mejor balance entre overfitting y underfitting

Pregunta 8

[Marcar pregunta](#)**Correcta**

Se puntúa 0,40 sobre 0,40

Empareje las opciones mas adecuadas sobre protocolos de evaluación

Si el dataset tiene 1000 datos entrena 1000 modelos

LOOCV



Es la mejor opción de evaluación de un modelo cuyo tiempo de entrenamiento sea muy largo

Hold-out



Permite reducir la incertidumbre con respecto a la calidad de la predicción de un modelo, sin ser prohibitivo en cuanto a tiempo de ejecución

K-Fold CV



Es ideal para evaluar modelos entrenados sobre un dataset pequeño

LOOCV



Respuesta correcta

La respuesta correcta es: Si el dataset tiene 1000 datos entrena 1000 modelos → LOOCV, Es la mejor opción de evaluación de un modelo cuyo tiempo de entrenamiento sea muy largo → Hold-out, Permite reducir la incertidumbre con respecto a la calidad de la predicción de un modelo, sin ser prohibitivo en cuanto a tiempo de ejecución → K-Fold CV, Es ideal para evaluar modelos entrenados sobre un dataset pequeño → LOOCV

Pregunta 9

[Marcar pregunta](#)

Correcta

Se puntúa 0,20 sobre 0,20

Trabajas con un conjunto de datos que no es linealmente separable. Se discuten dos opciones: usar SVM con un kernel polinomial grado 2 o con un kernel RBF. **¿Cuál afirmación debería guiar tu elección?**

- ☐ a. El Kernel RBF sólo sirve para datos linealmente separables.
- ☐ b. El Kernel polinomial siempre tiene menor complejidad computacional.
- ☐ c. El Kernel polinomial no requiere ajuste de hiperparámetros.
- ☒ d. RBF generaliza mejor en alta dimensionalidad. ✓

Respuesta correcta

El kernel **RBF** maneja bien relaciones complejas en espacios de alta dimensión.

Polinomial puede ser computacionalmente costoso dependiendo del grado.

RBF se usa precisamente para no linealidades.

Polinomial también requiere ajustar grado y coeficientes.

La respuesta correcta es: **RBF generaliza mejor en alta dimensionalidad.**

Pregunta 10

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Un analista argumenta que "Random Forest y XGBoost son equivalentes porque ambos usan árboles y agregan predicciones".

¿Cuál es una diferencia crítica?

- ☒ a. XGBoost construye árboles de forma secuencial para corregir errores de predictores anteriores (boosting), Random Forest no. ✓
- ☐ b. XGBoost usa solo árboles de decisión de un sólo nivel.
- ☐ c. Random Forest ajusta árboles de forma secuencial, XGBoost en paralelo.
- ☐ d. Random Forest ajusta árboles usando el algoritmo de gradiente descendente, XGBoost no.

Respuesta correcta

XGBoost usa **Boosting**, es decir, entrena árboles secuencialmente corrigiendo errores del predictor anterior vía gradiente.

Los árboles no necesariamente son de un solo nivel en XGBoost.

Random Forest ajusta en paralelo, no secuencial.

Random Forest no utiliza optimización basada en gradientes.

La respuesta correcta es:

XGBoost construye árboles de forma secuencial para corregir errores de predictores anteriores (boosting), Random Forest no.

Pregunta 11

[Marcar pregunta](#)

Correcta

Se puntúa 0,25 sobre 0,25

Entrenas una SVM con kernel RBF y notas que al incrementar c obtienes 100% de precisión en entrenamiento pero bajo desempeño en validación. **¿Qué sugiere este comportamiento?**

- ☒ a. Sobreajuste (overfitting). ✓
- ☐ b. Subajuste (underfitting).
- ☐ c. La necesidad de usar un kernel lineal.
- ☐ d. γ debe aumentarse.

Respuesta correcta

Un c muy alto penaliza mucho errores, forzando al modelo a ajustarse a cada punto → **overfitting**.

Subajuste sería baja precisión en entrenamiento.

Kernel RBF es adecuado para no linealidades.

Aumentar γ también podría aumentar sobreajuste.

La respuesta correcta es: **Sobreajuste (overfitting)**.

Pregunta 12

[Marcar pregunta](#)

Correcta

Se puntúa 0,25 sobre 0,25

¿Cuál es el objetivo principal de una máquina de vectores de soporte (SVM) en problemas de clasificación?

- ☐ a. Minimizar la distancia entre los datos y el hiperplano de separación.
- ☒ b. Maximizar el margen entre las clases mientras se minimizan los errores de clasificación. ✓ En una máquinas de vectores de soporte, dichos vectores "soportan" el hiperplano que maximiza el margen de separación de clases (hard margin) permitiendo algunos errores (soft margin)
- ☐ c. Maximizar el número de datos correctamente clasificados.
- ☐ d. Minimizar el tiempo de entrenamiento en grandes conjuntos de datos.

Respuesta correcta

La respuesta correcta es:

Maximizar el margen entre las clases mientras se minimizan los errores de clasificación.

Pregunta 13

[Marcar pregunta](#)**Correcta**

Se puntúa 0,40 sobre 0,40

A continuación encuentra bloques de código correspondientes a diferentes tipos de modelos de ensamble (# Definición del modelo), elija la opción adecuada según el caso. Tenga presente que cada uno hace parte del siguiente esquema :

Definición del dataset

```
X, y = make_classification(n_samples=1000, n_features=20, random_state=5)
```

Definición del modelo

...

Evaluación del modelo

```
cv = KFold(n_splits=5, shuffle=True, random_state=1)
```

```
n_scores = cross_val_score(model, X, y, scoring='accuracy', cv=cv, n_jobs=-1)
```

Definición del modelo

```
model = BaggingClassifier(max_samples=1.0, max_features=1.0,  
bootstrap=True, bootstrap_features=False, oob_score=True)
```

Bagging



Definición del modelo

```
model = BaggingClassifier(max_samples=0.5, max_features=1.0,  
bootstrap=False)
```

Pasting



Definición del modelo

```
model = BaggingClassifier(max_samples=0.75, max_features=0.75,  
bootstrap=True, bootstrap_features=True)
```

Random Patches



Definición del modelo

```
model = BaggingClassifier(max_samples=1.0, max_features=0.75,  
bootstrap=False, bootstrap_features=True)
```

Random Subspaces

**Respuesta correcta**

La respuesta correcta es:

Definición del modelo

model = BaggingClassifier(max_samples=1.0, max_features=1.0, bootstrap=True, bootstrap_features=False, oob_score=True) → Bagging,

Definición del modelo

model = BaggingClassifier(max_samples=0.5, max_features=1.0, bootstrap=False) → Pasting,

Definición del modelo

model = BaggingClassifier(max_samples=0.75, max_features=0.75, bootstrap=True, bootstrap_features=True) → Random Patches,

Definición del modelo

model = BaggingClassifier(max_samples=1.0, max_features=0.75, bootstrap=False, bootstrap_features=True) → Random Subspaces

Pregunta 14

[Marcar pregunta](#)

Correcta

Se puntúa 0,40 sobre 0,40

Empareje cada término relacionado con el algoritmo XGBoost y su mejor descripción.

Método aplicado para controlar la complejidad del modelo XGBoost al penalizar coeficientes de características menos importantes

Regularización L2 (Ridge) o L1 (Lasso)



Estructura base para la construcción del modelo en XGBoost

Árbol de decisión



Parámetro que controla la contribución de cada árbol al modelo final en XGBoost.

Learning rate



Técnica principal que impulsa el rendimiento del modelo mediante la combinación de múltiples árboles débiles

Gradient Boosting



Respuesta correcta

La respuesta correcta es:

Método aplicado para controlar la complejidad del modelo XGBoost al penalizar coeficientes de características menos importantes → Regularización L2 (Ridge) o L1 (Lasso),

Estructura base para la construcción del modelo en XGBoost → Árbol de decisión,

Parámetro que controla la contribución de cada árbol al modelo final en XGBoost.→ Learning rate,

Técnica principal que impulsa el rendimiento del modelo mediante la combinación de múltiples árboles débiles → Gradient Boosting

Pregunta 15

[Marcar pregunta](#)

Parcialmente correcta

Se puntúa 0,22 sobre 0,25

¿Cuáles de las siguientes afirmaciones son verdaderas sobre la métrica de clasificación ROC AUC?

- ☒ a. El AUC (Area Under the Curve) de la curva ROC puede tener un valor máximo de 1. ✓
- ☒ b. El AUC es una medida de la capacidad de un modelo de clasificación para discriminar entre clases positivas y negativas. ✓
- ☒ c. Un valor ROC AUC de 0.5 indica un rendimiento del modelo equivalente al azar. ✓
- ☒ d. ROC AUC es independiente de la distribución de clases en el conjunto de datos. ✗

Respuesta parcialmente correcta.

Ha seleccionado demasiadas opciones.

Las respuestas correctas son:

El AUC (Area Under the Curve) de la curva ROC puede tener un valor máximo de 1,

Un valor ROC AUC de 0.5 indica un rendimiento del modelo equivalente al azar.'

El AUC es una medida de la capacidad de un modelo de clasificación para discriminar entre clases positivas y negativas.

[Finalizar revisión](#)