

5

Métodos de remuestreo

Los métodos de remuestreo son una herramienta indispensable en la estadística moderna. Implican extraer repetidamente muestras de un conjunto de entrenamiento y reajustar un modelo de interés en cada muestra para obtener información adicional sobre el modelo ajustado. Por ejemplo, para estimar la variabilidad del ajuste de una regresión lineal, podemos extraer repetidamente diferentes muestras de los datos de entrenamiento, ajustar una regresión lineal a cada nueva muestra y, a continuación, examinar en qué medida difieren los ajustes resultantes. Este enfoque puede permitirnos obtener información que no estaría disponible ajustando el modelo una sola vez con la muestra de entrenamiento original.

Los métodos de remuestreo pueden ser computacionalmente costosos, ya que implican ajustar el mismo método estadístico varias veces utilizando diferentes subconjuntos de los datos de entrenamiento. Sin embargo, gracias a los recientes avances en potencia computacional, los requisitos computacionales de los métodos de remuestreo generalmente no son prohibitivos. En este capítulo, analizamos dos de los métodos de remuestreo más utilizados: la validación cruzada y el bootstrap. Ambos métodos son herramientas importantes en la aplicación práctica de muchos procedimientos de aprendizaje estadístico. Por ejemplo, la validación cruzada puede utilizarse para estimar el error de prueba asociado a un método de aprendizaje estadístico determinado con el fin de evaluar su rendimiento o para seleccionar el nivel adecuado de flexibilidad. El proceso de evaluar el rendimiento de un modelo se conoce como evaluación del modelo, mientras que el proceso de seleccionar el nivel adecuado de flexibilidad para un modelo se conoce como selección del modelo de evaluación. El bootstrap se utiliza en diversos contextos, más comúnmente para proporcionar una medida de la precisión de la estimación de un parámetro o de un método de aprendizaje estadístico de selección determinado.

5.1 Validación cruzada

En el Capítulo 2, analizamos la distinción entre la tasa de error de prueba y la tasa de error de entrenamiento. El error de prueba es el error promedio resultante de usar un método de aprendizaje estadístico para predecir la respuesta en una nueva observación; es decir, una medición que no se utilizó en el entrenamiento del método. Dado un conjunto de datos, se justifica el uso de un método de aprendizaje estadístico específico si resulta en un error de prueba bajo. El error de prueba se puede calcular fácilmente si se dispone de un conjunto de prueba designado. Desafortunadamente, esto no suele ser así.

En cambio, el error de entrenamiento se puede calcular fácilmente aplicando el método de aprendizaje estadístico a las observaciones utilizadas en su entrenamiento. Sin embargo, como vimos en el Capítulo 2, la tasa de error de entrenamiento suele ser bastante diferente de la tasa de error de prueba, y en particular, la primera puede subestimar considerablemente a la segunda.

En ausencia de un conjunto de prueba designado muy grande que permita estimar directamente la tasa de error de prueba, se pueden emplear diversas técnicas para estimar esta cantidad utilizando los datos de entrenamiento disponibles. Algunos métodos realizan un ajuste matemático a la tasa de error de entrenamiento para estimar la tasa de error de prueba. Estos enfoques se describen en el capítulo 6.

En esta sección, en cambio, consideramos una clase de métodos que estiman la tasa de error de prueba manteniendo un subconjunto de las observaciones de entrenamiento del proceso de ajuste y luego aplicando el método de aprendizaje estadístico a esas observaciones mantenidas.

En las Secciones 5.1.1–5.1.4, para simplificar, asumimos que nos interesa realizar una regresión con una respuesta cuantitativa. En la Sección 5.1.5, consideramos el caso de la clasificación con una respuesta cualitativa. Como veremos, los conceptos clave se mantienen independientemente de si la respuesta es cuantitativa o cualitativa.

5.1.1 El enfoque del conjunto de validación

Supongamos que queremos estimar el error de prueba asociado con el ajuste de un método de aprendizaje estadístico particular en un conjunto de observaciones. El enfoque del conjunto de validación, que se muestra en la Figura 5.1, es una estrategia muy simple para esta tarea. Implica dividir aleatoriamente el conjunto de observaciones disponible en dos partes: un conjunto de entrenamiento y un conjunto de validación o conjunto de reserva. El modelo se ajusta al conjunto de entrenamiento y el modelo ajustado se utiliza para predecir las respuestas para las observaciones en el conjunto de validación. La tasa de error del conjunto de validación resultante, generalmente evaluada mediante MSE en el caso de una respuesta cuantitativa, proporciona una estimación de la tasa de error de prueba.

validación

validación

colocar

conjunto de retención

Ilustramos el enfoque del conjunto de validación en el conjunto de datos **Auto**. Recordemos del Capítulo 3 que parece existir una relación no lineal entre el consumo de **combustible (mpg)** y **los caballos de fuerza**, y que un modelo que predice **el consumo de combustible** utilizando **los caballos de fuerza** y **los caballos de fuerza**² ofrece mejores resultados que un modelo que utiliza solo un término lineal. Es natural preguntarse si un ajuste cúbico o de orden superior podría proporcionar



FIGURA 5.1. Representación esquemática del enfoque del conjunto de validación. Un conjunto de n observaciones se divide aleatoriamente en un conjunto de entrenamiento (mostrado en azul, que contiene las observaciones 7, 22 y 13, entre otras) y un conjunto de validación (mostrado en beige, que contiene la observación 91, entre otras). El método de aprendizaje estadístico se ajusta al conjunto de entrenamiento y su rendimiento se evalúa en el conjunto de validación.

resultados aún mejores. Respondemos a esta pregunta en el Capítulo 3 al observar los valores p asociados con un término cúbico y términos polinomiales de orden superior en una regresión lineal. Pero también podríamos responder a esta pregunta usando el método de validación. Dividimos aleatoriamente las 392 observaciones en dos conjuntos, un conjunto de entrenamiento que contiene 196 de los puntos de datos y un conjunto de validación que contiene las 196 observaciones restantes. Las tasas de error del conjunto de validación que resultan del ajuste de varios modelos de regresión en la muestra de entrenamiento y la evaluación de su rendimiento en la muestra de validación, utilizando MSE como una medida del error del conjunto de validación, se muestran en el panel izquierdo de la Figura 5.2. El MSE del conjunto de validación para el ajuste cuadrático es considerablemente menor que para el ajuste lineal. Sin embargo, el MSE del conjunto de validación para el ajuste cúbico es en realidad ligeramente mayor que para el ajuste cuadrático. Esto implica que incluir un término cúbico en la regresión no conduce a una mejor predicción que simplemente usar un término cuadrático.

Recordemos que, para crear el panel izquierdo de la Figura 5.2, dividimos aleatoriamente el conjunto de datos en dos partes: un conjunto de entrenamiento y un conjunto de validación. Si repetimos el proceso de dividir aleatoriamente el conjunto de muestra en dos partes, obtenemos una estimación ligeramente diferente del MSE de prueba. A modo de ilustración, el panel derecho de la Figura 5.2 muestra diez curvas de MSE del conjunto de validación diferentes del conjunto de datos **Auto**, generadas mediante diez divisiones aleatorias diferentes de las observaciones en los conjuntos de entrenamiento y validación. Las diez curvas indican que el modelo con un término cuadrático tiene un MSE del conjunto de validación significativamente menor que el modelo con solo un término lineal. Además, las diez curvas indican que no hay mucho beneficio en incluir términos cúbicos o polinómicos de orden superior en el modelo. Sin embargo, cabe destacar que cada una de las diez curvas resulta en una estimación diferente del MSE de prueba para cada uno de los diez modelos de regresión considerados. Y no hay consenso entre las curvas sobre qué modelo resulta en el MSE del conjunto de validación más pequeño.

Basándonos en la variabilidad entre estas curvas, lo único que podemos concluir con seguridad es que el ajuste lineal no es adecuado para estos datos.

El enfoque del conjunto de validación es conceptualmente simple y fácil de implementar. Sin embargo, presenta dos posibles inconvenientes:




FIGURA 5.2. El enfoque del conjunto de validación se utilizó en el conjunto de datos **Auto** en **Para** estimar el error de prueba que resulta de predecir **mpg** usando polinomios **Funciones de los caballos de fuerza**. Izquierda: Estimaciones del error de validación para una sola división en **Conjuntos de datos de entrenamiento y validación**. Derecha: El método de validación se repitió diez veces, **veces, cada vez utilizando una división aleatoria diferente de las observaciones en un entrenamiento y un conjunto de validación**. Esto ilustra la variabilidad en el **MSE de prueba estimado**, **que resulta de este enfoque**.

1. Como se muestra en el panel derecho de la Figura 5.2, la estimación de validación de la tasa de error de prueba puede ser muy variable, dependiendo precisamente de qué observaciones se incluyen en el conjunto de entrenamiento y cuáles **Las observaciones se incluyen en el conjunto de validación**.
2. En el enfoque de validación, solo un subconjunto de las observaciones (aquellas que se incluyen en el conjunto de entrenamiento en lugar de en la validación conjunto—se utilizan para ajustar el modelo. Dado que los métodos estadísticos tienden a tener un peor rendimiento cuando se entrenan con menos observaciones, esto sugiere que **La tasa de error del conjunto de validación puede tender a sobreestimar la tasa de error de prueba para que el modelo se ajuste a todo el conjunto de datos**.

En las siguientes subsecciones, presentaremos la validación cruzada, un refinamiento de **El enfoque del conjunto de validación que aborda estas dos cuestiones**.

5.1.2 Validación cruzada de dejar uno fuera

La validación cruzada de dejar uno fuera (LOOCV) está estrechamente relacionada con el enfoque del conjunto de validación de la Sección 5.1.1, pero intenta abordar las necesidades de ese método. **Desventajas**.

dejar-uno-
afuera
cruz-
validación

Al igual que el enfoque del conjunto de validación, LOOCV implica dividir el conjunto de observaciones en dos partes. Sin embargo, en lugar de crear dos subconjuntos de tamaño comparable, se utiliza una sola observación (x_1, y_1) para la validación conjunto, y las observaciones restantes $\{(x_2, y_2), \dots, (x_n, y_n)\}$ forman el **Conjunto de entrenamiento**. El método de aprendizaje estadístico se ajusta al conjunto de entrenamiento $n - 1$ observaciones, y se hace una predicción $\hat{y}_1$ para la observación excluida, usando su valor x_1 . Dado que (x_1, y_1) no se utilizó en el proceso de ajuste, $MSE_1 =$




FIGURA 5.3. Representación esquemática de LOOCV. Un conjunto de n puntos de datos se divide repetidamente en un conjunto de entrenamiento (mostrado en azul) que contiene todas las observaciones menos una, y un conjunto de validación que contiene solo esa observación (mostrado en beige). El error de prueba se estima promediando los n MSE resultantes. El primer conjunto de entrenamiento contiene todas las observaciones menos la 1, el segundo conjunto de entrenamiento contiene todas las observaciones menos la 2, y así sucesivamente.

$(y_1 - \hat{y}_1)^2$ proporciona una estimación aproximadamente imparcial del error de prueba. Pero aunque MSE_1 no tiene sesgo en cuanto al error de prueba, es una estimación pobre porque es altamente variable, ya que se basa en una sola observación (x_1, y_1) .

Podemos repetir el procedimiento seleccionando (x_i, y_i) como datos de validación, entrenando el procedimiento de aprendizaje estadístico con las $n - 1$ observaciones $\{(x_1, y_1), (x_2, y_2), \dots, (x_i, y_i), \dots, (x_n, y_n)\}$ y calculando $MSE_i = (y_i - \hat{y}_i)^2$. Repetir este método n veces produce n errores al cuadrado, $MSE_1, \dots, MSE_n$.

La estimación de LOOCV para el MSE de prueba es el promedio de estas n estimaciones de error de prueba:

$$CV(n) = \frac{1}{n} \sum_{i=1}^n MSE_i. \tag{5.1}$$

En la Figura 5.3 se ilustra un esquema del enfoque LOOCV.

LOOCV tiene un par de ventajas importantes sobre el enfoque del conjunto de validación. En primer lugar, presenta un sesgo mucho menor. En LOOCV, ajustamos repetidamente el método de aprendizaje estadístico utilizando conjuntos de entrenamiento que contienen $n - 1$ observaciones, casi tantas como las del conjunto de datos completo. Esto contrasta con el enfoque del conjunto de validación, en el que el conjunto de entrenamiento suele tener aproximadamente la mitad del tamaño del conjunto de datos original. En consecuencia, el enfoque LOOCV tiende a no sobreestimar la tasa de error de prueba tanto como lo hace el enfoque del conjunto de validación. En segundo lugar, a diferencia del enfoque de validación, que producirá resultados diferentes al aplicarse repetidamente debido a la aleatoriedad en las divisiones de los conjuntos de entrenamiento/validación, realizar LOOCV varias veces...




FIGURA 5.4. Se utilizó la validación cruzada en el conjunto de datos **automáticos** para estimar el error de prueba que resulta de predecir el **mpg** usando funciones polinómicas de **caballos de fuerza**. Izquierda: La curva de error LOOCV. Derecha: Se ejecutó un CV de 10 veces nueve veces. momentos separados, cada uno con una división aleatoria diferente de los datos en diez partes. El La figura muestra las nueve curvas de error CV ligeramente diferentes.

siempre producen los mismos resultados: no hay aleatoriedad en las divisiones del conjunto de entrenamiento/validación.

Utilizamos LOOCV en el conjunto de datos **Auto** para obtener una estimación del conjunto de prueba MSE que resulta de ajustar un modelo de regresión lineal a

Predecir el **consumo de combustible** mediante funciones polinómicas de **caballos de fuerza**. Los resultados se muestran a continuación. en el panel izquierdo de la Figura 5.4.

LOOCV tiene el potencial de ser costoso de implementar, ya que el modelo tiene que ajustarse n veces. Esto puede llevar mucho tiempo si n es grande y si Cada modelo individual se ajusta lentamente. Con mínimos cuadrados lineales o polinómicos regresión, un atajo sorprendente hace que el costo de LOOCV sea el mismo que el de ¡De un ajuste de modelo único! La siguiente fórmula es válida:

$$CV(n) = \frac{1}{n} \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{1 - h_{ii}}, \quad (5.2)$$

donde $\hat{y}_i$ es el i -ésimo valor ajustado del ajuste de mínimos cuadrados original, y h_{ii} es el apalancamiento definido en (3.37) en la página 98. Esto es como el MSE ordinario, excepto que el i -ésimo residuo se divide entre $1 - h_{ii}$. El apalancamiento se encuentra entre $1/n$ y 1, y refleja la cantidad en que una observación influye en su propio ajuste.

Por lo tanto, los residuos de los puntos de alto apalancamiento se inflan en esta fórmula por exactamente la cantidad correcta para que se mantenga esta igualdad.

LOOCV es un método muy general y se puede utilizar con cualquier tipo de Modelado predictivo. Por ejemplo, podríamos usarlo con regresión logística. o análisis discriminante lineal, o cualquiera de los métodos discutidos más adelante.




FIGURA 5.5. Representación esquemática del CV quintuple. Un conjunto de n observaciones se divide aleatoriamente en cinco grupos no superpuestos. Cada uno de estos quintos actúa como conjunto de validación (mostrado en beige) y el resto como conjunto de entrenamiento (mostrado en azul). El error de prueba se estima promediando las cinco estimaciones de MSE resultantes.

capítulos. La fórmula mágica (5.2) no se cumple en general, en cuyo caso el modelo debe reajustarse n veces.

5.1.3 Validación cruzada de k-fold

Una alternativa a LOOCV es el CV de k pliegues. Este enfoque implica dividir aleatoriamente el conjunto de observaciones en k grupos, o pliegues, de tamaño aproximadamente igual. El primer pliegue se considera un conjunto de validación y el método se ajusta a los $k - 1$ pliegues restantes. A continuación, se calcula el error cuadrático medio (MSE1) de las observaciones del pliegue excluido. Este procedimiento se repite k veces; cada vez, un grupo diferente de observaciones se considera un conjunto de validación. Este proceso da como resultado k estimaciones del error de prueba (MSE1, MSE2,..., MSEk). La estimación del CV de k pliegues se calcula promediando estos valores.

CV de pliegue k

$$CV(k) = \frac{1}{k} \sum_{i=1}^k MSE_i. \tag{5.3}$$

La figura 5.5 ilustra el enfoque CV de k pliegues.

No es difícil ver que LOOCV es un caso especial de CV de k -fold en el que k se establece igual a n . En la práctica, uno típicamente realiza CV de k -fold usando $k = 5$ o $k = 10$. ¿Cuál es la ventaja de usar $k = 5$ o $k = 10$ en lugar de $k = n$? La ventaja más obvia es computacional. LOOCV requiere ajustar el método de aprendizaje estadístico n veces. Esto tiene el potencial de ser computacionalmente costoso (excepto para modelos lineales ajustados por mínimos cuadrados, en cuyo caso se puede usar la fórmula (5.2)). Pero la validación cruzada es un enfoque muy general que se puede aplicar a casi cualquier método de aprendizaje estadístico. Algunos métodos de aprendizaje estadístico tienen procedimientos de ajuste computacionalmente intensivos, por lo que realizar LOOCV puede plantear problemas computacionales, especialmente si n es extremadamente grande. Por el contrario, realizar 10-fold




FIGURA 5.6. MSE de prueba verdadero y estimado para los conjuntos de datos simulados en las Figuras 2.9 (izquierda), 2.10 (centro) y 2.11 (derecha). El MSE de prueba verdadero se muestra en azul, la estimación de LOOCV se muestra como una línea discontinua negra y el CV de 10 veces La estimación se muestra en naranja. Las cruces indican el mínimo de cada uno de los Curvas MSE.

El CV requiere realizar el procedimiento de aprendizaje solo diez veces, lo que puede ser mucho más factible. Como vemos en la Sección 5.1.4, también puede haber otras ventajas no computacionales al realizar un CV de 5 o 10 veces, que implican el equilibrio entre sesgo y varianza.

El panel derecho de la Figura 5.4 muestra nueve CV de 10 pliegues diferentes. Estimaciones para el conjunto de datos **automáticos**, cada una resultante de un análisis aleatorio diferente. división de las observaciones en diez partes. Como podemos ver en la figura, hay Existe cierta variabilidad en las estimaciones del CV como resultado de la variabilidad en cómo Las observaciones se dividen en diez partes. Pero esta variabilidad es típicamente mucho menor que la variabilidad en las estimaciones de error de prueba que resulta de el enfoque del conjunto de validación (panel derecho de la Figura 5.2).

Cuando examinamos datos reales, no conocemos el verdadero MSE de prueba y Por lo tanto, es difícil determinar la precisión de la estimación de validación cruzada. Sin embargo, si examinamos datos simulados, podemos calcular el valor real. Probar MSE y, por lo tanto, evaluar la precisión de nuestra validación cruzada. Resultados. En la Figura 5.6, graficamos las estimaciones de validación cruzada y la prueba verdadera. tasas de error que resultan de aplicar splines de suavizado a la simulación conjuntos de datos ilustrados en las figuras 2.9-2.11 del Capítulo 2. El verdadero MSE de prueba se muestra en azul. Las líneas discontinuas negras y continuas naranjas respectivamente Muestra las estimaciones de LOOCV y CV de 10 veces. En los tres gráficos, Las dos estimaciones de validación cruzada son muy similares. En el panel derecho De la Figura 5.6, el MSE de prueba real y las curvas de validación cruzada son casi idénticos. En el panel central de la Figura 5.6, los dos conjuntos de curvas son similares. en los grados más bajos de flexibilidad, mientras que las curvas CV sobreestiman la prueba Establezca MSE para mayores grados de flexibilidad. En el panel izquierdo de la Figura 5.6, Las curvas CV tienen la forma general correcta, pero subestiman la verdadera prueba MSE.

Al realizar una validación cruzada, nuestro objetivo podría ser determinar el rendimiento esperado de un procedimiento de aprendizaje estadístico con datos independientes; en este caso, la estimación real del MSE de prueba es de interés. Sin embargo, en otras ocasiones, solo nos interesa la ubicación del punto mínimo en la curva de MSE de prueba estimada. Esto se debe a que podríamos estar realizando una validación cruzada con varios métodos de aprendizaje estadístico o con un solo método que utiliza diferentes niveles de flexibilidad para identificar el método que genera el menor error de prueba. Para ello, la ubicación del punto mínimo en la curva de MSE de prueba estimada es importante, pero el valor real de este no lo es. En la Figura 5.6, observamos que, a pesar de que a veces subestiman el MSE de prueba real, todas las curvas CV se acercan a la identificación del nivel correcto de flexibilidad, es decir, el nivel de flexibilidad correspondiente al MSE de prueba más pequeño.

5.1.4 Compensación entre sesgo y varianza para la validación cruzada de k pliegues

En la Sección 5.1.3 mencionamos que el CV de k -fold con $k < n$ ofrece una ventaja computacional sobre LOOCV. Sin embargo, dejando de lado los problemas computacionales, una ventaja menos obvia, pero potencialmente más importante, del CV de k -fold es que suele proporcionar estimaciones más precisas de la tasa de error de prueba que LOOCV. Esto se relaciona con un equilibrio entre sesgo y varianza.

Se mencionó en la Sección 5.1.1 que el enfoque del conjunto de validación puede llevar a sobreestimaciones de la tasa de error de prueba, ya que en este enfoque el conjunto de entrenamiento utilizado para ajustar el método de aprendizaje estadístico contiene solo la mitad de las observaciones de todo el conjunto de datos. Usando esta lógica, no es difícil ver que LOOCV proporcionará estimaciones aproximadamente insesgadas del error de prueba, ya que cada conjunto de entrenamiento contiene $n - 1$ observaciones, que es casi tantas como el número de observaciones en el conjunto de datos completo. Y realizar un CV de k -fold para, digamos, $k = 5$ o $k = 10$ conducirá a un nivel intermedio de sesgo, ya que cada conjunto de entrenamiento contiene $(k - 1)n/k$ observaciones, menos que en el enfoque LOOCV, pero sustancialmente más que en el enfoque del conjunto de validación. Por lo tanto, desde la perspectiva de la reducción del sesgo, es claro que LOOCV es preferible al CV de k -fold.

Sin embargo, sabemos que el sesgo no es la única fuente de preocupación en un procedimiento de estimación; también debemos considerar la varianza del procedimiento. Resulta que LOOCV tiene mayor varianza que el CV de k -fold con $k < n$. ¿A qué se debe esto? Al realizar LOOCV, en efecto, promediamos los resultados de n modelos ajustados, cada uno de los cuales se entrena con un conjunto de observaciones casi idéntico; por lo tanto, estos resultados están altamente correlacionados (positivamente). Por el contrario, al realizar el CV de k -fold con $k < n$, promediamos los resultados de k modelos ajustados que están algo menos correlacionados entre sí, ya que el solapamiento entre los conjuntos de entrenamiento en cada modelo es menor. Dado que la media de muchas cantidades altamente correlacionadas

tiene una varianza mayor que la media de muchas cantidades que no están tan altamente correlacionadas, la estimación del error de prueba resultante de LOOCV tiende a tener una varianza mayor que la estimación del error de prueba resultante de CV k-fold.

En resumen, existe una compensación entre sesgo y varianza asociada a la elección de k en la validación cruzada de k-fold. Normalmente, dadas estas consideraciones, se realiza la validación cruzada de k-fold utilizando $k = 5$ o $k = 10$, ya que se ha demostrado empíricamente que estos valores producen estimaciones de la tasa de error de prueba que no presentan un sesgo excesivamente alto ni una varianza muy alta.

5.1.5 Validación cruzada en problemas de clasificación

En este capítulo, hemos ilustrado el uso de la validación cruzada en el contexto de regresión donde el resultado Y es cuantitativo, por lo que hemos utilizado el MSE para cuantificar el error de prueba. Sin embargo, la validación cruzada también puede ser un enfoque muy útil en el contexto de clasificación cuando Y es cualitativo. En este contexto, la validación cruzada funciona igual que se describió anteriormente en este capítulo, excepto que, en lugar de utilizar el MSE para cuantificar el error de prueba, utilizamos el número de observaciones mal clasificadas. Por ejemplo, en el contexto de clasificación, la tasa de error LOOCV toma la forma

$$CV(n) = \frac{1}{n} \sum_{i=1}^n \text{Erri}, \quad (5.4)$$

donde $\text{Erri} = I(y_i \neq \hat{y}_i)$. La tasa de error CV de k-fold y las tasas de error del conjunto de validación se definen de forma análoga.

A modo de ejemplo, ajustamos varios modelos de regresión logística a los datos de clasificación bidimensional que se muestran en la Figura 2.13. En el panel superior izquierdo de la Figura 5.7, la línea continua negra muestra el límite de decisión estimado resultante de ajustar un modelo de regresión logística estándar a este conjunto de datos. Dado que se trata de datos simulados, podemos calcular la tasa de error de prueba real, que toma un valor de 0,201 y, por lo tanto, es sustancialmente mayor que la tasa de error bayesiana de 0,133. Es evidente que la regresión logística no tiene la flexibilidad suficiente para modelar el límite de decisión bayesiano en este contexto. Podemos extender fácilmente la regresión logística para obtener un límite de decisión no lineal mediante el uso de funciones polinómicas de los predictores, como hicimos en el contexto de regresión de la Sección 3.3.2. Por ejemplo, podemos ajustar un modelo de regresión logística cuadrática, dado por

$$\text{registro} = \frac{\text{pag}}{1 - p} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1^2 + \beta_4 X_2^2 \quad (5.5)$$

El panel superior derecho de la Figura 5.7 muestra el límite de decisión resultante, que ahora es curvo. Sin embargo, la tasa de error de prueba solo ha mejorado ligeramente, hasta 0,197. Una mejora mucho mayor se aprecia en el panel inferior izquierdo.




FIGURA 5.7. Ajustes de regresión logística en los datos de clasificación bidimensional mostrados en la Figura 2.13. El límite de decisión bayesiano se representa mediante una línea discontinua morada. Los límites de decisión estimados de las regresiones logísticas lineal, cuadrática, cúbica y cuártica (grados 1-4) se muestran en negro. Las tasas de error de prueba para los cuatro ajustes de regresión logística son, respectivamente, 0,201, 0,197, 0,160 y 0,162, mientras que la tasa de error bayesiana es de 0,133.

Figura 5.7, donde ajustamos un modelo de regresión logística con polinomios cúbicos de los predictores. Ahora, la tasa de error de prueba ha disminuido a 0,160. Al usar un polinomio de cuarto grado (abajo a la derecha), el error de prueba aumenta ligeramente.

En la práctica, para datos reales, se desconocen el límite de decisión de Bayes y las tasas de error de prueba. Entonces, ¿cómo podríamos decidir entre los cuatro modelos de regresión logística que se muestran en la Figura 5.7? Podemos usar la validación cruzada para tomar esta decisión. El panel izquierdo de la Figura 5.8 muestra...




FIGURA 5.8. Error de prueba (marrón), error de entrenamiento (azul) y error de CV de 10 veces (negro) en los datos de clasificación bidimensional que se muestran en la Figura 5.7. Izquierda: Regresión logística utilizando funciones polinómicas de los predictores. El orden de Los polinomios utilizados se muestran en el eje x. Derecha: El clasificador KNN con diferentes valores de K, el número de vecinos utilizados en el clasificador KNN.

negro las tasas de error CV de 10 veces que resultan de ajustar diez modelos de regresión logística a los datos, utilizando funciones polinomiales de los predictores hasta hasta el décimo orden. Los errores de prueba reales se muestran en marrón y el entrenamiento Los errores se muestran en azul. Como hemos visto anteriormente, el error de entrenamiento tiende a disminuir a medida que aumenta la flexibilidad del ajuste. (La figura indica que aunque la tasa de error de entrenamiento no disminuye de manera monótona, Tiende a disminuir en general a medida que aumenta la complejidad del modelo). En Por el contrario, el error de prueba muestra una forma de U característica. El CV de 10 veces La tasa de error proporciona una aproximación bastante buena a la tasa de error de prueba. Si bien subestima un poco la tasa de error, alcanza un mínimo cuando se utilizan polinomios de cuarto orden, que está muy cerca del mínimo de la curva de prueba, lo que ocurre cuando se utilizan polinomios de tercer orden. usado. De hecho, el uso de polinomios de cuarto orden probablemente conduciría a una buena prueba. rendimiento del conjunto, ya que la tasa de error de prueba real es aproximadamente la misma para polinomios de tercer, cuarto, quinto y sexto orden.

El panel derecho de la Figura 5.8 muestra las mismas tres curvas utilizando el enfoque KNN para la clasificación, en función del valor de K (que en este contexto indica el número de vecinos utilizados en el KNN clasificador, en lugar del número de pliegues de CV utilizados). Nuevamente, el entrenamiento La tasa de error disminuye a medida que el método se vuelve más flexible, por lo que vemos que La tasa de error de entrenamiento no se puede utilizar para seleccionar el valor óptimo para K. Aunque la curva de error de validación cruzada subestima ligeramente la prueba tasa de error, toma un mínimo muy cercano al mejor valor para K.

5.2 El Bootstrap

El bootstrap es una herramienta estadística de amplia aplicación y extremadamente potente que permite cuantificar la incertidumbre asociada a un estimador o método de aprendizaje estadístico determinado. Como ejemplo sencillo, el bootstrap...

oreja

se puede utilizar para estimar los errores estándar de los coeficientes de una ecuación lineal. ajuste de regresión. En el caso específico de la regresión lineal, esto no es particularmente útil, ya que vimos en el Capítulo 3 que el software estadístico estándar como R genera automáticamente dichos errores estándar. Sin embargo, la potencia de la Bootstrap radica en el hecho de que se puede aplicar fácilmente a una amplia gama de métodos de aprendizaje estadístico, incluidos algunos para los cuales es difícil obtener una medida de variabilidad y no se emite automáticamente software estadístico.

En esta sección ilustramos el bootstrap en un ejemplo de juguete en el que deseo determinar la mejor asignación de inversión bajo un modelo simple.

En la Sección 5.3 exploramos el uso del bootstrap para evaluar la variabilidad asociado con los coeficientes de regresión en un ajuste de modelo lineal.

Supongamos que deseamos invertir una suma fija de dinero en dos entidades financieras. activos que generan rendimientos de X e Y , respectivamente, donde X e Y son cantidades aleatorias. Invertiremos una fracción α de nuestro dinero en X , y invertir el $1 - \alpha$ restante en Y . Dado que existe variabilidad asociada con Para calcular el rendimiento de estos dos activos, deseamos elegir α para minimizar el total. riesgo, o varianza, de nuestra inversión. En otras palabras, queremos minimizar $\text{Var}(\alpha X + (1 - \alpha)Y)$. Se puede demostrar que el valor que minimiza el riesgo viene dado por

$$\alpha = \frac{\sigma_Y^2 - \sigma_{XY}}{\sigma_X^2 + \sigma_Y^2 - 2\sigma_{XY}}, \quad (5.6)$$

donde $\sigma_X^2 = \text{Var}(X)$, $\sigma_Y^2 = \text{Var}(Y)$, y $\sigma_{XY} = \text{Cov}(X, Y)$.

En realidad, las cantidades σ_X^2 , σ_Y^2 , y σ_{XY} son desconocidos. Podemos calcular estimaciones para estas cantidades, $\hat{\sigma}_X^2$, $\hat{\sigma}_Y^2$, y $\hat{\sigma}_{XY}$, utilizando un conjunto de datos que contiene mediciones pasadas para X e Y . Luego podemos estimar el valor de α que minimiza la varianza de nuestra inversión utilizando

$$\hat{\alpha} = \frac{\hat{\sigma}_Y^2 - \hat{\sigma}_{XY}}{\hat{\sigma}_X^2 + \hat{\sigma}_Y^2 - 2\hat{\sigma}_{XY}}. \quad (5.7)$$

La figura 5.9 ilustra este enfoque para estimar α en datos simulados.

Conjunto. En cada panel, simulamos 100 pares de rendimientos para las inversiones.

X e Y . Usamos estos retornos para estimar σ_X^2 , σ_Y^2 , y σ_{XY} , que nosotros

luego se sustituye en (5.7) para obtener estimaciones de α . El valor de

El $\hat{\alpha}$ resultante de cada conjunto de datos simulados varía entre 0,532 y 0,657.

Es natural querer cuantificar la precisión de nuestra estimación de α .

Para estimar la desviación estándar de $\hat{\alpha}$, repetimos el proceso de simulación de 100 observaciones pareadas de X e Y , y estimando α usando (5.7),




FIGURA 5.9. Cada panel muestra 100 simulaciones de rentabilidad de las inversiones. X e Y. De izquierda a derecha y de arriba a abajo, las estimaciones resultantes para α son 0,576, 0,532, 0,657 y 0,651.

1.000 veces. De este modo, obtuvimos 1.000 estimaciones para α , que podemos llamar $\alpha^1, \alpha^2, \dots, \alpha^{1.000}$. El panel izquierdo de la Figura 5.10 muestra un histograma de las estimaciones resultantes. Para estas simulaciones, los parámetros se establecieron en $\sigma^2_{\epsilon} = 1$, $\sigma^2_{\gamma} = 1,25$, y $\sigma_{XY} = 0,5$, por lo que sabemos que el valor verdadero de α es 0,6. Indicamos este valor mediante una línea vertical continua en el histograma. La media de las 1000 estimaciones para α es

$$\bar{\alpha} = \frac{1}{1.000} \sum_{r=1}^{1.000} \alpha^r = 0,5996,$$

muy cerca de $\alpha = 0,6$, y la desviación estándar de las estimaciones es

$$\frac{1}{1.000 - 1} \sum_{r=1}^{1.000} (\alpha^r - \bar{\alpha})^2 = 0,083.$$

Esto nos da una muy buena idea de la precisión de $\hat{\alpha}$: $SE(\hat{\alpha}) \approx 0,083$. Por lo tanto En términos generales, para una muestra aleatoria de la población, tendríamos Se espera que $\hat{\alpha}$ difiera de α en aproximadamente 0,08, en promedio.

En la práctica, sin embargo, el procedimiento para estimar $SE(\hat{\alpha})$ descrito anteriormente No se puede aplicar, porque para datos reales no podemos generar nuevas muestras. de la población original. Sin embargo, el enfoque bootstrap nos permite utilizar una computadora para emular el proceso de obtención de nuevos conjuntos de muestras,




FIGURA 5.10. Izquierda: Un histograma de las estimaciones de α obtenidas al generar 1.000 conjuntos de datos simulados de la población real. Centro: Un histograma de la Estimaciones de α obtenidas a partir de 1.000 muestras bootstrap de un único conjunto de datos. Derecha: Las estimaciones de α que se muestran en los paneles izquierdo y central se muestran como Diagramas de caja. En cada panel, la línea rosa indica el valor real de α .

de modo que podamos estimar la variabilidad de $\hat{\alpha}$ sin generar variables adicionales. muestras. En lugar de obtener repetidamente conjuntos de datos independientes de la población, en cambio obtenemos conjuntos de datos distintos mediante muestreos repetidos observaciones del conjunto de datos original.

Este enfoque se ilustra en la Figura 5.11 en un conjunto de datos simple, que Llamamos Z , que contiene solo $n = 3$ observaciones. Seleccionamos n al azar. observaciones del conjunto de datos para producir un conjunto de datos bootstrap, Z_1 . El muestreo se realiza con reemplazo, lo que significa que la misma observación puede ocurrir más de una vez en el conjunto de datos bootstrap. En este ejemplo, Z_1 contiene la tercera observación dos veces, la primera observación una vez, y ninguna instancia de la segunda observación. Tenga en cuenta que si una observación está contenido en Z_1 , entonces se incluyen sus valores X e Y . Podemos usar Z_1 para producir una nueva estimación bootstrap para α , que llamamos $\hat{\alpha}_1$. Esto El procedimiento se repite B veces para un valor grande de B , con el fin de producir B diferentes conjuntos de datos bootstrap, $Z_1, Z_2, \dots, Z_B$ y B α correspondiente estimaciones, $\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_B$. Podemos calcular el error estándar de estas Estimaciones bootstrap usando la fórmula

$$SEB(\hat{\alpha}) = \sqrt{\frac{1}{B-1} \sum_{r=1}^B (\hat{\alpha}_r - \bar{\alpha})^2} \tag{5.8}$$

Esto sirve como una estimación del error estándar de $\hat{\alpha}$ estimado a partir de la conjunto de datos original.

El enfoque bootstrap se ilustra en el panel central de la Figura 5.10. que muestra un histograma de 1000 estimaciones bootstrap de α , cada una calculada utilizando un conjunto de datos bootstrap distinto. Este panel se construyó en la base de un único conjunto de datos y, por lo tanto, podrían crearse utilizando datos reales.




FIGURA 5.11. Una ilustración gráfica del enfoque bootstrap en un pequeño Muestra con $n = 3$ observaciones. Cada conjunto de datos bootstrap contiene n observaciones, muestreadas con reemplazo del conjunto de datos original. Cada conjunto de datos bootstrap El conjunto se utiliza para obtener una estimación de α .

Nótese que el histograma se ve muy similar al panel de la izquierda, que muestra el histograma idealizado de las estimaciones de α obtenidas al generar 1000 conjuntos de datos simulados de la población real. En particular, la estimación bootstrap $SE(\hat{\alpha})$ de (5.8) es de 0,087, muy cercana a la estimación de 0,083. obtenidos utilizando 1.000 conjuntos de datos simulados. El panel derecho muestra la información en los paneles central e izquierdo de una manera diferente, a través de diagramas de caja de Las estimaciones de α se obtuvieron generando 1000 conjuntos de datos simulados a partir de la población real y utilizando el método bootstrap. Nuevamente, los diagramas de caja son bastante similares entre sí, lo que indica que el enfoque bootstrap puede se puede utilizar para estimar eficazmente la variabilidad asociada con $\hat{\alpha}$.

5.3 Laboratorio: Validación cruzada y Bootstrap

En este laboratorio, exploramos las técnicas de remuestreo cubiertas en este capítulo. Algunos de los comandos de este laboratorio pueden tardar un tiempo en ejecutarse en su computadora.