



APRENDIZAJE NO SUPERVISADO





OBJETIVOS ESPECIFICOS

1. Identificar problemáticas que se puedan resolver a partir de modelos de aprendizaje no supervisado.
2. Aplicar modelos de segmentación de datos (*clustering*) como K-Means o clustering jerárquico.
3. Aplicar modelos de reducción de dimensionalidad de los datos como PCA.
4. Reconocer como establecer los mejores valores de los parámetros de los modelos de aprendizaje no supervisado.



Aprendizaje supervisado

- Aprender a partir de un “experto”
- Datos de entrenamiento **etiquetados** con una clase o valor:

$(\underbrace{x_1, x_2, \dots, x_n}_{\text{Predictores, explicativos, independientes}}, \underbrace{y}_{\text{Dependiente, objetivo, salida}})$

- **Meta:** predecir una clase o valor

Aprendizaje no supervisado

- Sin conocimiento de una clase o valor objetivo

- Datos **no** están **etiquetados**

$(x_1, x_2, \dots, x_n)$

- **Meta:** descubrir factores no observados, estructura, o una representación mas simple de los datos



APRENDIZAJE AUTOMÁTICO

Aprendizaje supervisado

Edad	Ingresos	Tiene carro?
24	1'200.000	NO
23	4'500.000	SI
45	1'250.000	SI
32	1'100.000	NO

Factores/atributos/variables independientes,
predictores, explicativos

Dependiente, objetivo,
respuesta, salida

34	3'500.000
----	-----------

¿Cuál es el valor predicho
para una instancia dada?

Aprendizaje no supervisado

Edad	Ingresos
24	1'200.000
23	4'500.000
45	1'250.000
32	1'100.000

Factores/atributos/variables

Datos no etiquetados:
“¿Qué me puede decir
de mis datos?”

¿Se puede encontrar alguna
estructura en los datos?



APRENDIZAJE NO SUPERVISADO

- No se interesa por la predicción sino por encontrar una estructura, un nuevo punto de vista, una simplificación o un resumen de los datos
- Usualmente se incluye en la fase exploratoria de datos
- Tipos de tareas:
 - Segmentación (clustering)
 - Cambio de representación (e.g. reducción de dimensiones, selección de factores)
 - Reglas de asociación
 - Detección de anomalías (i.e. excepciones)
- Difícil de validar los resultados, ya que no se cuenta con un “gold standard”




CLUSTERING



CLUSTERING

- No se tiene una variable objetivo
- Se busca agrupar los datos similares para encontrar patrones globales de los datos
- Agrupamiento por **similitud, proximidad, densidad**
- Particionar un conjunto en grupos, de forma tal que elementos en un mismo grupo sean similares entre sí y tan diferentes como sea posible de elementos en otros grupos.




<http://pypr.sourceforge.net/kmeans.html>




CLUSTERING POR DISTANCIA

- Objetivo: descubrir **k** grupos o segmentos desconocidos que
 - Minimicen la distancia dentro de los grupos
 - Maximicen la distancia por fuera de los grupos
- Se basan en una noción de **distancia**
 - Definición de la medida a utilizar
 - Unidades de los atributos tienen gran influencia
 - **Normalizar**
 - **Estandarizar**



<http://pypr.sourceforge.net/kmeans.html>






How many clusters?



CLUSTERING POR DISTANCIA

- Se pueden buscar segmentos de observaciones o de atributos
- No existe un método universal absoluto para establecer **k**, solo heurísticas
- Requiere juicio humano, más difícil de automatizar
- La interpretación de los resultados no se debe de hacer de manera absoluta, sino como un punto de partida para el análisis
- Los datos pueden no tener estructura, por lo cual su segmentación podría no tener sentido




<http://governingstochastic.weebly.com/blog/category/clustering>



CLUSTERING – DISTANCIAS

- Medidas de **similitud** o **distancia**:


- Euclidiana**: tamaño del segmento lineal que une las dos instancias comparadas.



$$d(\mathbf{p}, \mathbf{q}) = d(\mathbf{q}, \mathbf{p}) = \sqrt{(q_1 - p_1)^2 + (q_2 - p_2)^2 + \dots + (q_n - p_n)^2}$$


$$= \sqrt{\sum_{i=1}^n (q_i - p_i)^2}.$$

- Manhattan**: basada en una organización en bloques rectilíneos




- Coseno**: coseno del ángulo entre las dos instancias comparadas → Alta dimensionalidad y **big data**


$$sim(\mathbf{x}, \mathbf{y}) = \cos(\theta_{\mathbf{x}, \mathbf{y}}) = \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} = \frac{\sum_i x_i * y_i}{\sqrt{(\sum_i x_i * x_i) * \sum_i y_i * y_i}}$$



CLUSTERING



K-MEANS



K-MEANS



(a)

10/24




K-MEANS




(a)




(b)




(c)



(d)



(e)



(f)

¿Cuál es el algoritmo de lo que acabamos de ver?



K-MEANS

- Algoritmo:

1. Inicializar los K centroides
2. Asignar cada instancia al cluster del centroide más cercano
3. Re calcular los centroides de cada cluster (el baricentro/promedio)
4. Repetir pasos 2 y 3 hasta convergencia (hasta que los centroides permanezcan estáticos)

- Cada observación se asigna a un solo cluster, de manera absoluta
- Los clusters no se sobrelapan
- Objetivo: minimizar la variación dentro de los clusters (Within Sum of Squares - WSS):

$$WSS = \sum_{i=1}^{\#instancias} distancia(\mathbf{x}_i - \text{centroide}(\mathbf{x}_i))^2$$



K-MEANS

■ Consideraciones:

- ¿Cómo estimar el número de clusters (K)?
 - Mardia (1979): $\sqrt{n/2}$
 - Método “del codo”
 - Método Silhouette
 - Medida de CH
- ¿Cómo inicializar los centroides de los clusters?
 - Escoger centros completamente aleatorios
 - Escoger puntos existentes aleatoriamente
 - Escoger los centroides utilizando K-Means ++






K-MEANS

Posgrados

- **Consideraciones:**

- ¿Cómo evitar los óptimos locales?
 - Ejecutar varias veces el algoritmo con diferentes inicializaciones, seleccionar el clustering con el mínimo WSS



K-MEANS


- **Consideraciones:**
 - Algoritmo de particionamiento, fácil de implementar
 - Más rápido que clustering jerárquico
 - Sólo trabaja con atributos numéricos (noción de promedio)
 - Muy sensible a excepciones
 - Funciona muy bien con datos generados siguiendo un proceso Gaussiano,
 - No funciona para identificar clusters con formas no convexas



TALLER: K-MEANS — CLIENTES SUPERMERCADOS


Desarrollar el taller de clustering de clientes de supermercados S6_Kmeans-PCA-Supermercados (hasta antes de la determinación del k).





EVALUACIÓN DE CLUSTERING

ESCOGENCIA DEL K




http://scikit-learn.org/stable/auto_examples/cluster/plot_kmeans_silhouette_analysis.html



ESCOGENCIA DEL K – CODO

- **Heurísticos:**
 - No hay un método absoluto
 - Dependen del juicio del analista, se requiere conocimiento del negocio
- **Método “del codo”:**
 - Plotear WSS para cada valor de K
 - Escoger el último valor de K que implica una reducción “considerable” del WSS del clustering resultante, cuando la curva se vuelve aproximadamente lineal




$$WSS = \sum_{i=1}^{\#instancias} distancia(x_i - centroide(x_i))^2$$



ESCOGENCIA DEL K – SILHOUETTE

- Método Silhouette
 - Se busca el K que maximice la **separación** entre clusters, con clusters lo más **compactos** posibles
 - Analizar el ajuste de cada instancia al cluster al que fue asignado
 - Qué tan cerca está cada observación de las demás de su propio cluster
 - 0,7-1,0: el cluster es fuertemente robusto
 - 0,5-0,7: el cluster es razonablemente robusto
 - 0,25-0,5: el cluster puede ser artificial y puede no denotar una noción de estructura necesariamente
 - Inferior a 0,25: el cluster debería descartarse, no indica estructura
 - Se busca la maximización del valor Silhouette promedio de los clusters



ESCOGENCIA DEL K – SILUETA

■ Método Silueta (Silhouette)

- Calcular el valor de silueta de cada punto:
 - Cohesión del punto con su cluster C_i (promedio de distancias con puntos de su mismo cluster):


$$cohesión(p) = a(p) = \frac{\sum_{p' \in C_i, p' \neq p} distancia(p, p')}{|C_i| - 1}$$

- Separación de los puntos de otros clusters (distancia promedio con los puntos del cluster más cercano):

$$separación(p) = b(p) = \min_{C_j: 1 \leq j \leq k, j \neq i} \left(\frac{\sum_{p' \in C_j} distancia(p, p')}{|C_j|} \right)$$

- El valor de silueta del punto es entonces:

$$silueta(p) = s(p) = \frac{b(p) - a(p)}{\max(b(p), a(p))}$$



ESCOGENCIA DEL K – SILUETA

- Método Silueta (Silhouette)

- Calcular el valor de silueta de cada cluster (promedio de las siluetas de sus puntos).


$$silueta(C_i) = \frac{1}{|C_i|} \sum_{p \in C_i} s(p)$$

- Analizar los puntos y clusters, buscando posibles problemas de asignación dados por el valor del K:
 - El rango de la silueta está entre -1 y 1
 - Una silueta de 0 implica que la asignación de un punto a su cluster es indiferente
 - Se espera que los puntos del mismo cluster estén más cercanos al punto en cuestión: para que la silueta sea positiva tenemos que $a(p) < b(p)$




ESCOGENCIA DEL K – SILUETA


Silhouette analysis for KMeans clustering on sample data with $n_clusters = 2$




Silhouette analysis for KMeans clustering on sample data with $n_clusters = 4$



Silhouette analysis for KMeans clustering on sample data with $n_clusters = 3$




Silhouette analysis for KMeans clustering on sample data with $n_clusters = 5$



ESCOGENCIA DEL K — CALINSKI-HARABASZ

- Método de Calinski-Harabasz:
 - Se busca el K que maximice la **separación** entre clusters, con clusters lo más **compactos** posibles
 - TSS = variación total (entre todos los datos y el centro global)
 - WSS = variación intra-cluster (entre los puntos de cada cluster y sus centroides)
 - BSS = variación inter-cluster (entre los centroides de los clusters y el centro global).
BSS = TSS - WSS
 - CH = ratio entre la variación entre clusters (BSS) y el promedio de la variación interna de los clusters (WSS). Se busca maximizar CH:

$$CH = \frac{BSS}{WSS} * \frac{N - k}{k - 1}$$





TALLER: EVALUACIÓN DE CLUSTERING

Continuar con el taller de clustering de clientes de supermercado S6_Kmeans-PCA-Supermercados con la parte dedicada a la determinación y evaluación del número de clusters.



COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES


PCA: Principal Component Analysis

Objetivo: Simplificar el dataset, encontrando una representación de **baja dimensionalidad** que conserve la mayor parte de la información


- **Combinación lineal** de las dimensiones (atributos) originales del dataset que maximiza la varianza
- **Rotación** de los ejes originales
- Permite una **visualización** los datos en problemas de aprendizaje supervisado y no supervisado
- Se limitan los atributos altamente **correlacionados**
- PCA permite encontrar la superficie lineal de menos dimensiones más cercana a los puntos en el espacio original (en distancia Euclidiana)



REDUCCION DE DIMENSIONALIDAD CON COMPONENTES PRINCIPALES



(a) Dataset with x_1 and x_2 coordinates.



(b) Compressed dataset where only the x_1 coordinate is relevant.

Objetivo: Simplificar el dataset encontrando una representación de **baja dimensionalidad** que conserve la mayor parte de la información


- Por ejemplo, datos de alta dimensión (imágenes) suelen tener muchas dimensiones redundantes
- Los datos a menudo están **correlacionados**, pueden generarse desde una **dimensión inferior**
- Reducción de dimensionalidad explota: **estructura** y **correlación**, permite trabajar una representación más compacta, sin perder mucha información

<https://mml-book.com>



COMPONENTES PRINCIPALES

- PCA encuentra proyecciones $\widehat{X}_N$ de los datos X_N lo más similar posible a los datos originales, pero con una dimensionalidad significativamente más baja.
- Dado un dataset $(X_1, X_2, \dots, X_N)$, $X_N \in \mathbb{R}^D$, con media 0 se tiene la matriz de covarianza de datos $S = \frac{1}{N} \sum_{n=1}^N X_N X_N^T$,
- Además, asumimos que existe una representación comprimida de baja dimensión $Z_N = B^T X_N \in \mathbb{R}^M$, donde $B \in \mathbb{R}^{D \times M}$ es una matriz de proyección y $M \ll D$.



<https://mml-book.com>





Univ. Cauca
ICE

Polígrafos

COMPONENTES PRINCIPALES: DIRECCIÓN DE VARIANZA MÁXIMA

- Nuestro objetivo es maximizar la varianza de cada coordenada z_i de $Z \in R^M$ de forma tal que

$$V_j = Var[z_i] = \frac{1}{N} \sum_{n=1}^N z_{in}^2,$$

es maximizada.

- z_{in} es la i -ésima coordenada de la representación en baja dimensión $Z_N \in R^M$ de $X_N \in R^D$. Note que $Z_{jN} = b_j^T X_N$ luego

$$V_j = \frac{1}{N} \sum_{n=1}^N (b_j^T X_N)^2 = b_j^T \left(\frac{1}{N} \sum_{n=1}^N X_N X_N^T \right) b_j = b_j^T S b_j ,$$

- Por lo tanto, la dirección de máxima varianza puede encontrarse resolviendo el problema de optimización:

$$\begin{aligned} \max b_j^T S b_j \\ \text{s. t. } \|b_j\| = 1 \end{aligned}$$

- Utilizando multiplicadores de Lagrange se puede mostrar que la solución obedece las siguientes relaciones
- $$\begin{aligned} S b_j &= \lambda_j b_j \\ \|b_j\| &= 1 \end{aligned}$$



COMPONENTES PRINCIPALES

- Hay tantos componentes principales (PC) como atributos
- Cada PC es una combinación lineal normalizada de los atributos del dataset $(X_1, X_2, \dots, X_N)$, se buscan los vectores que maximicen la varianza


$$PC_i = \Phi_{1i}X_1 + \Phi_{2i}X_2 + \dots + \Phi_{Ni}X_N, \text{ sujeto a } \sum_{j=1}^N \Phi_{ji}^2 = 1, \forall j < i, PC_i \perp PC_j$$

- Cada PC es único y tiene asociada una carga o **loading** de cada una de las dimensiones originales (los Φ_{ji}).
- El vector de loadings de una variable original indica su dirección en el espacio de los PC
- A cada PC se le puede establecer la cantidad de información original especificada (proporción de varianza explicada).
- Los primeros PCs representan mucha más información que las primeras dimensiones originales
- Las instancias se proyectan en el espacio dado por los primeros PCs




COMPONENTES PRINCIPALES

	Mouse 1	Mouse 2	Mouse 3	Mouse 4	Mouse 5	Mouse 6
Gene 1	10	11	8	3	2	1
Gene 2	6	4	5	3	2.8	1




COMPONENTES PRINCIPALES


	Mouse 1	Mouse 2	Mouse 3	Mouse 4	Mouse 5	Mouse 6
Gene 1	10	11	8	3	2	1
Gene 2	6	4	5	3	2.8	1




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES



COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES

Se muestra que b y c están
inversamente relacionados

$$a^2 = b^2 + c^2$$




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES


Es más fácil trabajar maximizando c
(la suma de las distancias al cuadrado
del punto proyectado al origen)




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES




$d_1^2 + d_2^2 + d_3^2 + d_4^2 + d_5^2 + d_6^2 = \text{sum of squared distances} = \text{SS}(\text{distances})$




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES



COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES

La proporción de cada Gene se denomina Carga (loading)




COMPONENTES PRINCIPALES

$$d_1^2 + d_2^2 + d_3^2 + d_4^2 + d_5^2 + d_6^2 = \text{sum of squared distances} = \text{SS}(\text{distances})$$




COMPONENTES PRINCIPALES




COMPONENTES PRINCIPALES

Se escoge la línea que pase por el origen y sea perpendicular a PC1




COMPONENTES PRINCIPALES

Gene 2 es 4 veces más importante que Gene 1




COMPONENTES PRINCIPALES

Rotamos y utilizamos los puntos proyectados para encontrar las muestras




COMPONENTES PRINCIPALES

Rotamos y utilizamos los puntos proyectados para encontrar las muestras




COMPONENTES PRINCIPALES

Rotamos y utilizamos los puntos proyectados para encontrar las muestras




COMPONENTES PRINCIPALES

**Rotamos y utilizamos los puntos
proyectados para encontrar las
muestras**



COMPONENTES PRINCIPALES

Rotamos y utilizamos los puntos proyectados para encontrar las muestras




COMPONENTES PRINCIPALES

Si la variación de PC1
fuese 15 y la de PC2 3


$$\frac{SS(\text{distances for PC1})}{n - 1} = \text{Variation for PC1}$$

$$\frac{SS(\text{distances for PC2})}{n - 1} = \text{Variation for PC2}$$


La variación total en
ambos PCs es 18 y la
proporción de
varianza explicada
de PC1 es 83%





COMPONENTES PRINCIPALES



COMPONENTES PRINCIPALES



COMPONENTES PRINCIPALES



COMPONENTES PRINCIPALES

Consideraciones

- La varianza de cada uno de los atributos originales depende de su escala, por lo que se deben **normalizar** los datos originales
- Puede que la varianza esté bien distribuida en los atributos originales, por lo que aplicar PCA no tendría efecto
- Considerar solo las primeras componentes principales permite reducir la influencia del ruido en los datos.
- A partir de una transformación inversa del espacio de los PCs hacia el espacio original podemos entonces **filtrar el ruido**.



TALLER: COMPONENTES PRINCIPALES

1. Trabajar el cuaderno de clustering de clientes de supermercado S6_KMeans-PCA-Supermercados con la parte dedicada a la reducción de dimensionalidad a partir de PCA
2. Trabajar el cuaderno S6_USARRESTS-PCA






**Machine
Learning**




**Aprendizaje
Supervisado**




**Aprendizaje No
Supervisado**



**Hierarchichal
Clustering**




**Clustering
Evaluation**




K-means

Clustering





**Reducción de
Dimensionalidad**



**Principal Component
Analysis**




HIERARCHICAL CLUSTERING





HIERARCHICAL CLUSTERING

- **Bottom-up** approach
- Produce como resultado un **dendrograma**
- Basado en distancias entre instancias y entre clusters
- Permite visualizar y determinar todas las posibles segmentaciones
- Facilita la interpretación de las segmentaciones en forma de una **taxonomía**
- No necesita repetir el proceso para diferentes valores de **K**
- Instancias **excepcionales** pueden identificarse fácilmente




HIERARCHICAL CLUSTERING

- **Algorithm:**
 1. Inicialmente cada instancia determina su propio cluster
 2. Se identifica el par de clústeres más cercano y se fusiona en un nuevo clúster que los reemplaza.
 3. El paso anterior se repite hasta que solo haya un clúster con todas las instancias.
 4. Elija un punto de corte.
- Los clústeres se pueden organizar en forma de **dendrogramas**
- Las nociones de **fusion** entre clusters y **distancia** a usarse deben definirse



- **Fusion** entre clústeres basándose en el cálculo de las distancias entre todos los pares de puntos de uno y otro clúster:
 - **Single linkage:**
 - Distancia mínima entre dos puntos de los dos clústeres.
 - Los clústeres se componen de "cadenas" de puntos, generalmente con fusiones consecutivas entre un clúster y un punto cercano.
 - Sensible al ruido y a las excepciones.
 - **Complete linkage:**
 - Distancia máxima entre dos puntos de los dos cúmulos. Tiende a formar cúmulos esféricos con diámetros constantes.
 - **Average linkage:**
 - Promedio de las distancias entre todos los pares de puntos.
 - Punto intermedio entre el enlace simple y el completo.
 - Menos afectado por excepciones.



→ Complejidad computacional en **todas las** distancias




- Otros tipos de **cluster fusion**

- **Centroid:**

- Distancia entre los centroides de los clústeres
 - Usado en genómica
 - Sufre de inversiones, cuando el punto de fusión de dos clústeres en el dendrograma es menor que el de uno de los clústeres fusionados.

- **Ward:**

- Para cada fusión, se analiza el cambio en la varianza.
 - Con cada fusión, la varianza global del conjunto de clústeres aumenta.
 - Se elige la fusión cuyo aumento de varianza sea mínimo.



- **Consideraciones**

- Las instancias que pertenecen a los clústeres son absolutas.
- Requiere gran potencia computacional.
- Una vez que se decide la fusión, no hay vuelta atrás.
- No optimiza una función de coste.
- Dependiendo de la distancia utilizada y el tipo de fusión:
 - Sensible al ruido y a las excepciones.
 - Dificultad para identificar clústeres de diferentes tamaños o convexos.
 - Puede particionar clústeres grandes.
 - Influencia de las unidades de los atributos utilizados (□ estandarización).
- ¿Qué punto de corte, k, elegir?
- Se recomienda la intervención humana.



TALLER: CLUSTERING JERÁRQUICO

Desarrollar el jupyter notebook SYNTH- HClust de clustering jerárquico con datos sintéticos



- *Python Machine Learning*, Sebastian Raschka, Packt, 2015
- *Introduction to Statistical Learning with Applications in R (ISLR)*, G. James, D. Witten, T. Hastie & R. Tibshirani, 2014
- EMC2, “Data science and big data analytics”, 2015, John Wiley & Sons
- *Data Science for Business*, Foster Provost & Tom Fawcett, O’Reilly, 2013
- *Practical Data Science with R*, Nina Zumel & John Mount, 2014

