

Guía de lectura

Introduction to Statistical Learning. Springer, 2013

Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani

Capítulo 6, puntos 6.3 (intro) y 6.3.1 (Principal Components Regression)

Capítulo 10, puntos 10.1, 10.2, 10.3

Desarrolle los siguientes puntos basándose en la lectura. Se puede apoyar en fuentes adicionales (artículos, libros, internet). Tienen que poder responder a las siguientes preguntas:

- ¿En qué se diferencia el aprendizaje supervisado del no supervisado?

Clustering

- ¿Por qué el clustering es una tarea de aprendizaje no supervisado?
- ¿Qué tipo de problemas del mundo real podría resolver el clustering (vayan más allá de lo que está en el libro)?
- Describa el algoritmo de K-Means
- Describa el algoritmo de Clustering jerárquico
- ¿Qué similitudes y diferencias hay entre K-Means y clustering jerárquico?
- ¿Para qué puede servir un dendrograma?
- ¿Qué son y cuáles son las diferencias entre los criterios de fusión de clusters (single, complete, average y centroid) en el clustering jerárquico?

PCA

- Describa para qué sirve el algoritmo de PCA y en términos generales cómo funciona (sin detalle matemático)
- ¿En qué situaciones es útil, y en qué situaciones no lo es?
- ¿Qué tipo de problemas permite resolver el algoritmo PCA?
- ¿Cuál es el número de componentes principales resultantes de aplicar PCA a un dataset de 20 registros con 25 variables?
- ¿Cuál es el procedimiento para escoger el número de componentes principales a conservar si se quiere reducir el número de variables?
- ¿Qué relación existe entre PCA y los modelos de regresión lineal?
- ¿Se puede decir que al utilizar PCA se está seleccionando un subconjunto de las variables originales, pudiendo descartar las no seleccionadas?

Recomiendo el siguiente [video](#) de StatQuest relacionado con PCA.